Introdução a aprendizado de máquina

O que é, o que comem e como se reproduzem

Aprendizado de Máquina

- Estudo de algoritmos que melhoram automaticamente utilizando experiências
- Se, a partir de uma experiência E, o algoritmo melhora seu desempenho em uma tarefa, é possível dizer que ele aprendeu.
- Precisamos ter 3 componentes:
  - Tarefa
  - Fonte da experiência
  - Medida de desempenho

Definição de Mitchell

Um programa de computador é dito aprender a partir da experiência *E* a respeito de alguma classe de tarefas *T* e performance *P* se a sua performance em tarefas *T*, medidas por *P*, melhora com experiência *E*.

Problemas de Aprendizado Bem Formados

- Problemas bem formados é necessário identificar três características:
  - a classe da tarefa
  - a medida de performance a ser melhorada
  - fonte da experiência

Problemas de Aprendizado Bem Formados

- Jogando damas:
  - Tarefa: jogar dama
  - Medida de performance: porcentagem de jogos ganhos
  - Fonte de experiência: Jogar contra si
- Robô motorista:
  - Tarefa: dirigir em uma rodovia usando sensores de visão
  - Medida de performance: distância média antes de cometer algum erro
  - Fonte de experiência: Sequência de imagens e comandos gravados com um humano dirigindo

Problemas de Aprendizado Bem Formados

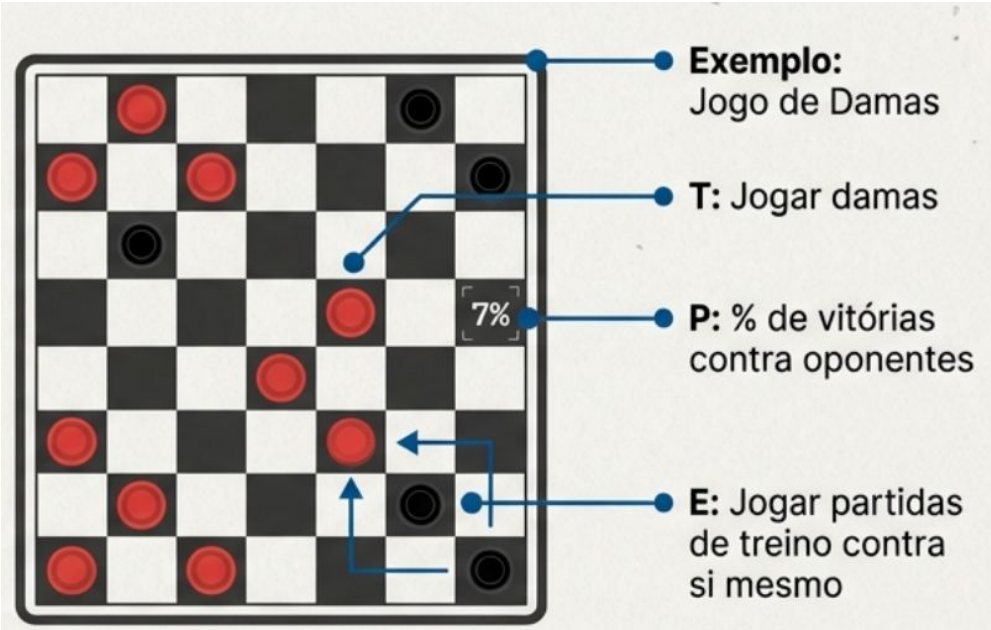

Espaço de hipótese

- Pode ser representado por:
  - Espaços contendo funções numéricas
  - Redes neurais
  - Árvores de decisão
  - Regras simbólicas

Espaço de hipótese

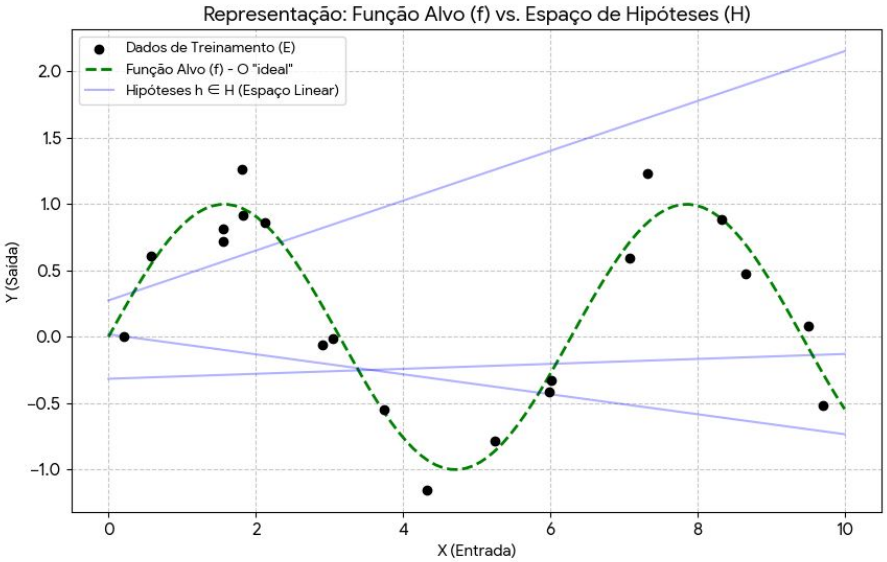

Espaço de hipótese

- O aprendizado pode ser visto como a tarefa de pesquisar através deste vasto espaço de hipóteses *H* para encontrar a hipótese que melhor se ajusta aos dados de treinamento observado.
- O espaço de hipóteses pode ser gigantesco. Em tarefas práticas o espaço pode ser infinito
- É comum que, dentro do espaço de hipótese, existe uma estrutura geral (como uma ordenação geral para específico)
- Possível usar essa estrutura para melhorar a busca pela melhor hipótese

Espaço de hipótese

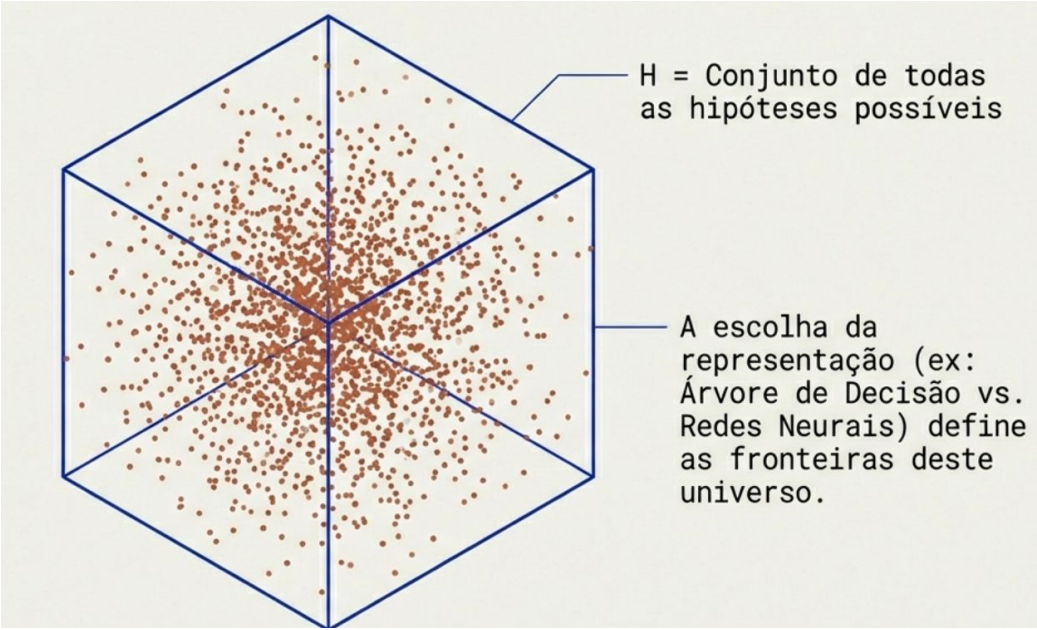

Espaço de hipótese

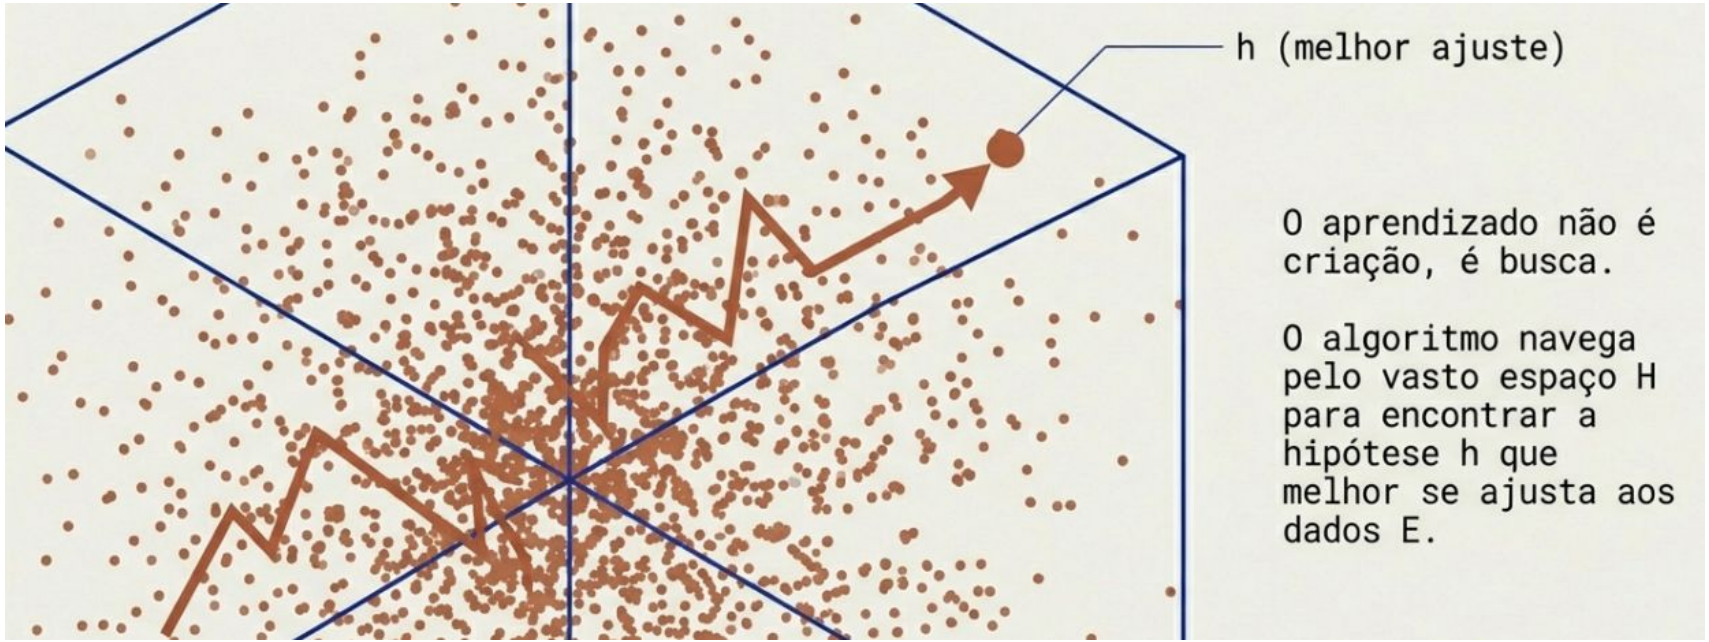

O aprendizado não é criação, é busca.

O algoritmo navega pelo vasto espaço H para encontrar a hipótese h que melhor se ajusta aos dados E.

Espaço de hipótese

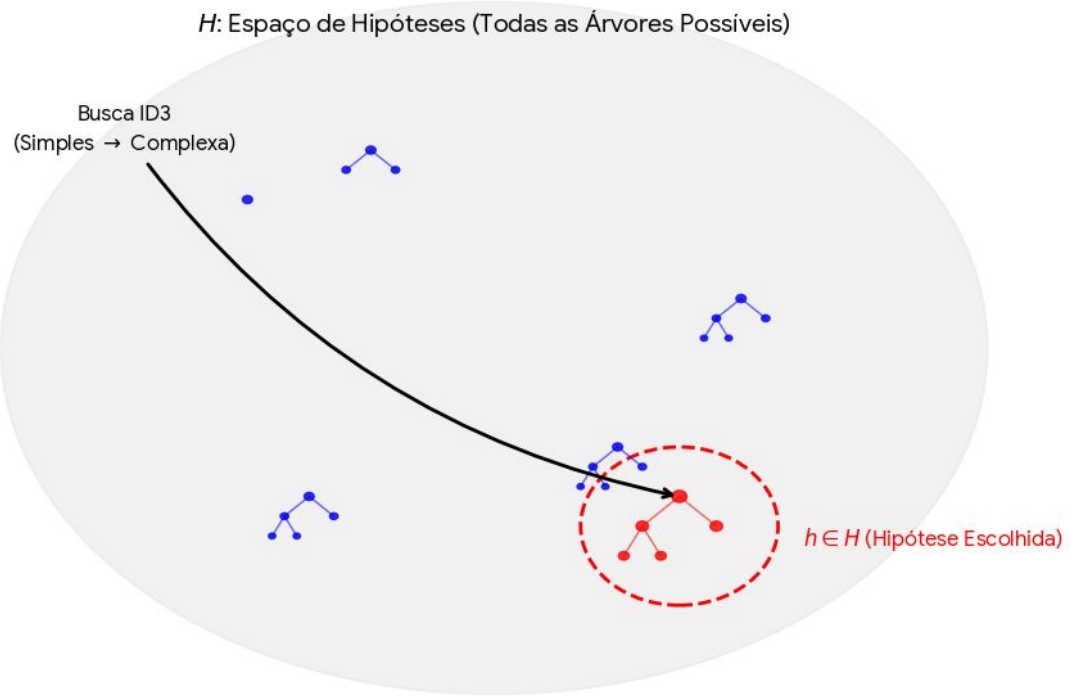

Espaço de hipótese

- Uma representação muito expressiva permite aproximar melhor a função alvo ideal
- Infelizmente isso requer mais dados de treinamento
- Uma representação mais simples requer menos dados, mas não é capaz de capturar a função alvo com precisão
- Isso é conhecido como **trade-off de precisão**

Trade-off de Precisão

- **Baixa expressividade (underfitting):** É o aluno que só decora uma frase para responder todas as questões da prova
- **Alta expressividade (overfitting):** É o aluno que decora até o número da página do livro, caso mude uma vírgula na questão da prova ele não consegue responder pois não estava igual ao que ele decorou
- **Generalização:** É o aluno que aprender a lógica por trás do assunto estudado e consegue resolver questões que nunca viu antes

Espaço de hipótese

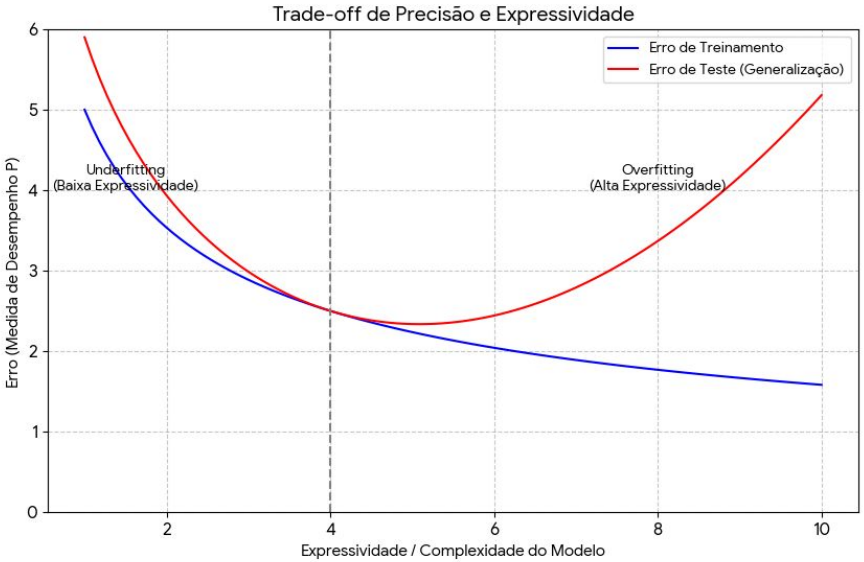

Generalização

- Habilidade de um algoritmo inferir a classificação de novas instâncias não observadas, baseando-se nas regularidades aprendidas a partir dos dados de treinamento
- É um dos principais objetivos de algoritmos de aprendizado de máquina
- A generalização se baseia na hipótese do aprendizado indutivo → qualquer hipótese que se aproxime bem a função algo em um conjunto suficientemente grande de treino também aproximará bem a função alvo em exemplos não observados

Viés indutivo

- Para que a generalização ocorra o aprendiz, nesse caso um modelo de AM, deve ter algum tipo de suposição prévia
- Um modelo que não tem faz suposições *a priori* sobre identidade do conceito alvo não tem base racional para classificar nenhuma instância que não tenha visto anteriormente
- O viés implícito é o que possibilita o salto indutivo (por exemplo: preferir árvores de decisão mais curtas). Sem o viés o sistema seria capaz apenas de aprendizado mecânico

Generalização VS Overfitting

- Overfitting é um fenômeno que, durante o treinamento, o modelo se ajusta perfeitamente aos dados de treinamento causando perda de performance em dados nunca antes vistos
- A generalização busca um equilíbrio entre aprender a estrutura subjacente dos dados sem memorizar o ruído
- Cada modelo generaliza de forma diferente:
    - Redes neurais é caracterizada como uma interpolação suave entre pontos de dados
    - Árvores de decisão preferem hipóteses mais simples

Erros de generalização

- Foca na distinção entre os erros observados nos dados de treinamento e o erro real que o sistema terá ao enfrentar novos dados no futuro
- É importante distinguir o erro de amostra e o erro verdadeiro
  - **Erro de amostra:** Fração de exemplos na amostra *S* que a hipótese *h* classifica incorretamente
  - **Erro verdadeiro:** Probabilidade de que a hipótese *h* classifique incorretamente uma única instância sorteada aleatoriamente da distribuição de probabilidade

Erro de generalização

- **Erro de amostra:** Nota que aluno tira fazendo os exercícios de casa
- **Erro verdadeiro:** Chance de ele errar qualquer questão aleatória que caia na prova oficial
- **OU SEJA** → tirar 10 nos exercícios de casa não quer dizer que você irá tirar 10 na prova

Erro de generalização

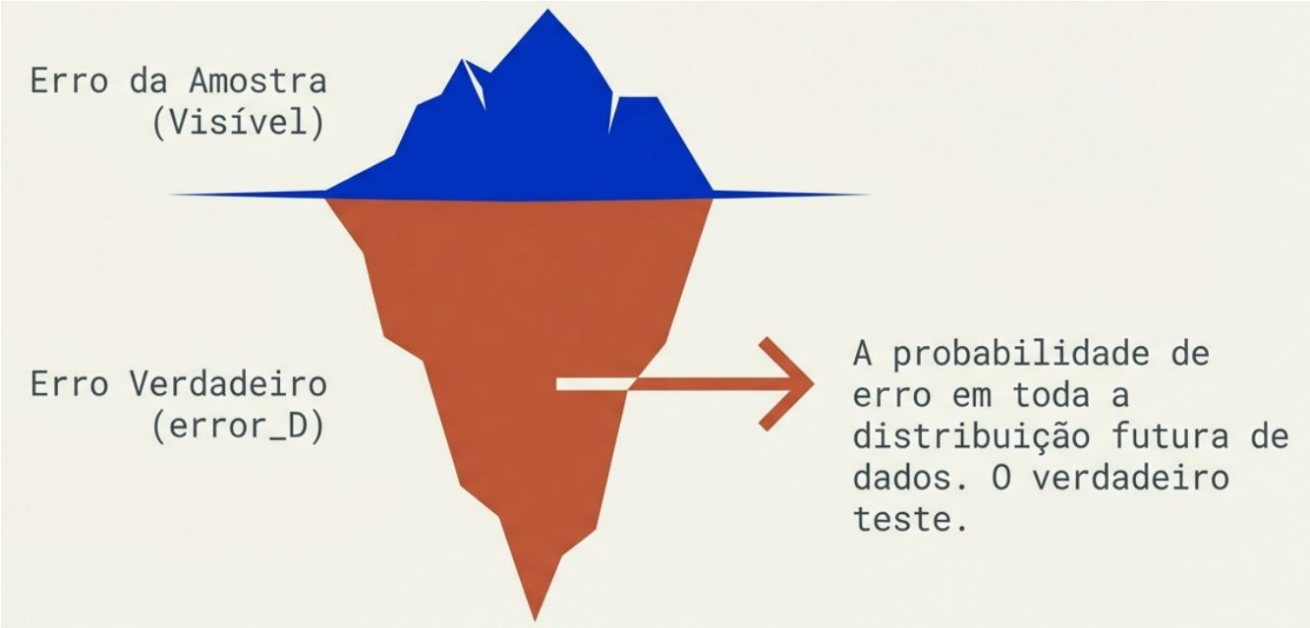

Erros de generalização

- Overfitting é um erro de generalização
- Como só é possível medir o erro da amostra é utilizado estatística para estimar a probabilidade de que o erro verdadeiro de uma certa margem do erro da amostra
    - Assumindo que os dados seguem uma distribuição fixa e não são independentes

Erros de generalização

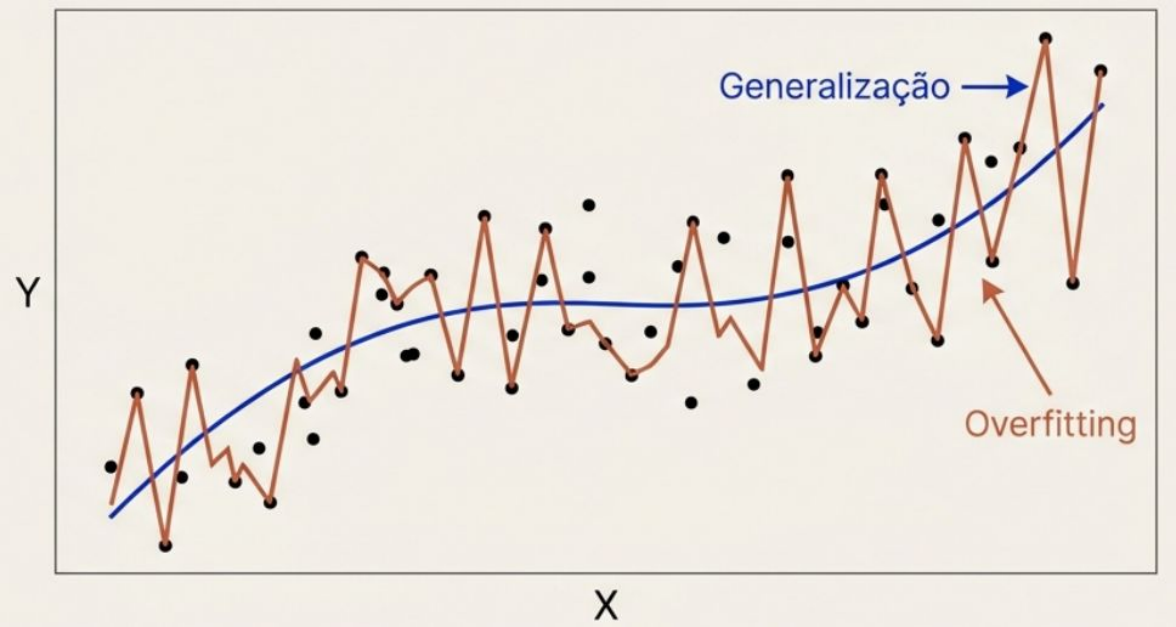

Diagnosticando o overfitting

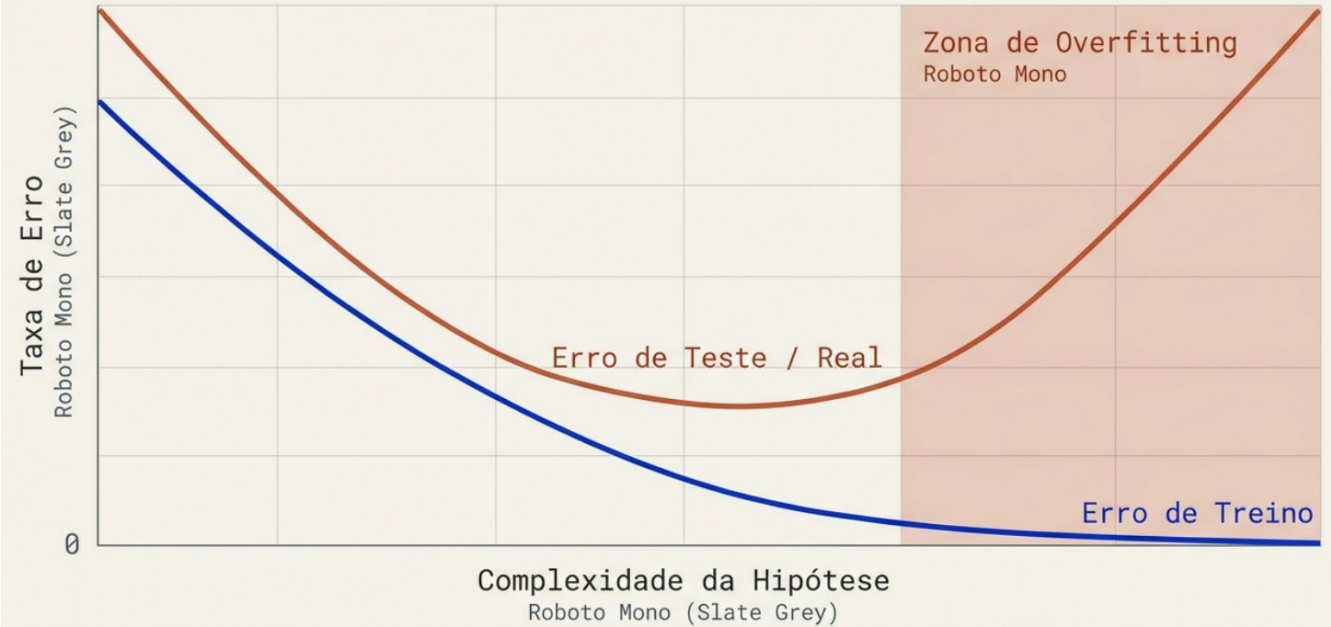

Viés de estimativa

- Discrepância sistemática entre o erro que é observado durante o treinamento e o erro real que o sistema terá no futuro. Alguns fatores implicam nisso:
- **Otimismo da amostra:** O erro calculado durante o treino é uma estimativa otimista do erro real
- Esse viés ocorre pois a hipótese selecionada foi justamente com o objetivo de se ajustar a esses dados específicos de treinamento
- É necessário o treino em exemplos não vistos pelo algoritmo, só assim o erro se aproxima do erro real

Viés de estimativa

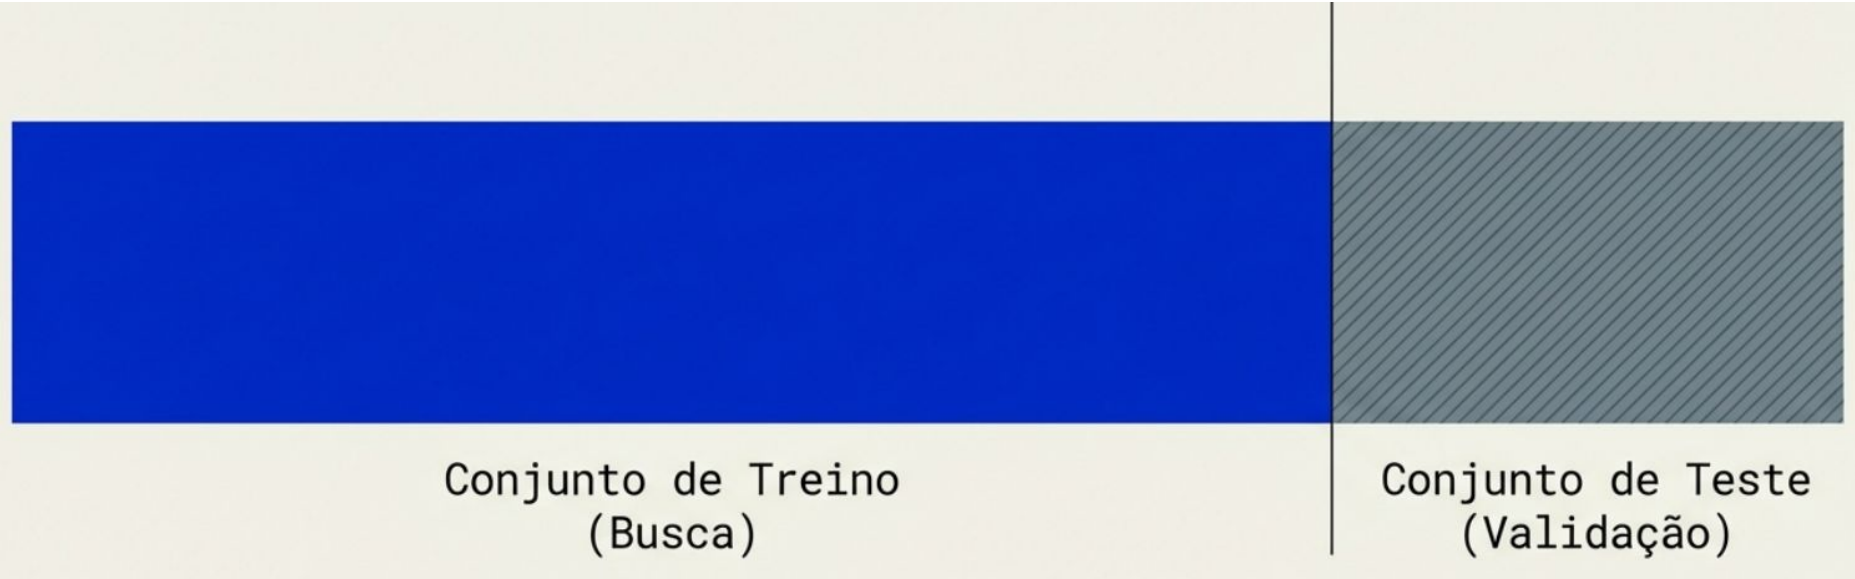

Síntese de um sistema de AM

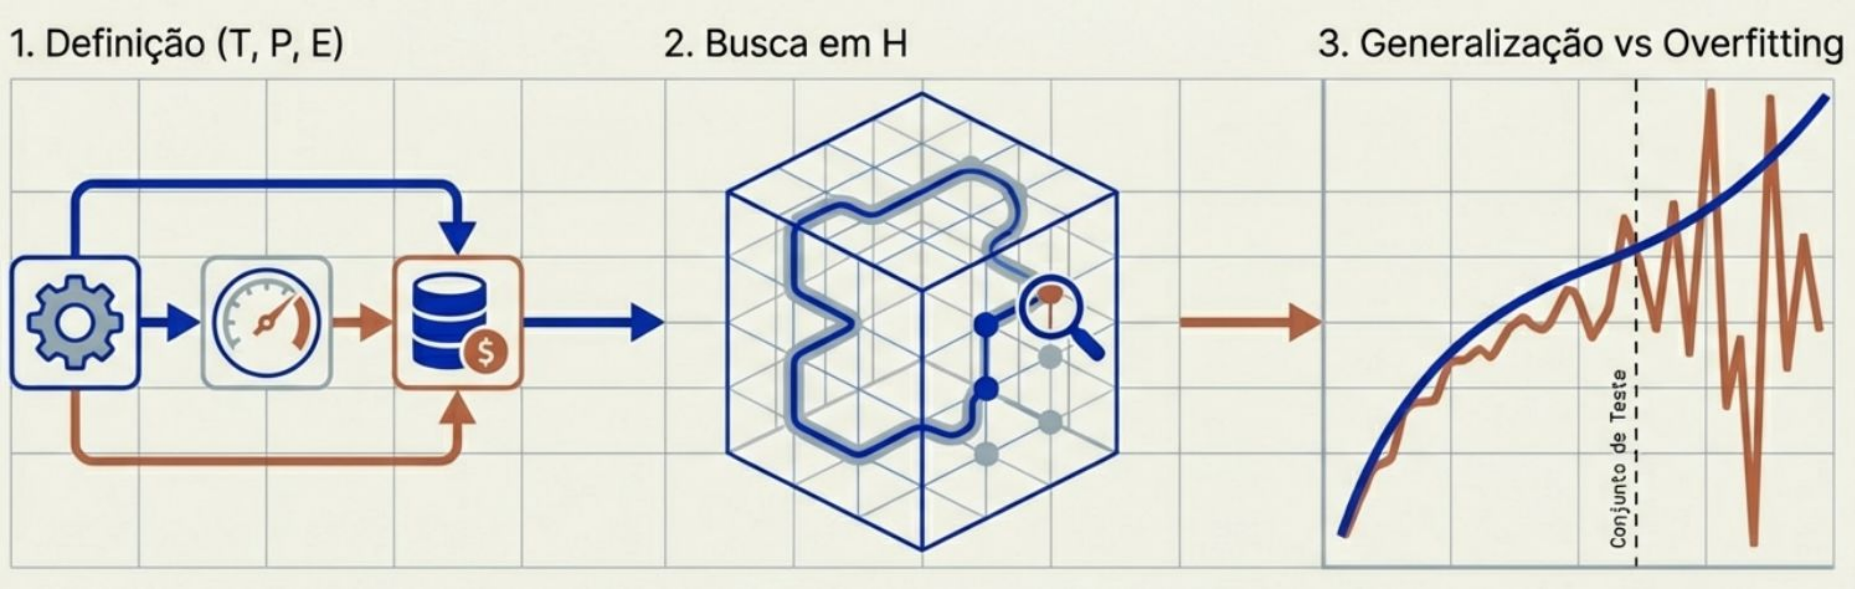

Espaço de hipótese

- **Definição:** O Espaço de Hipóteses, denotado pelo símbolo *H*, é o conjunto de todas as possíveis hipóteses que o aprendiz pode considerar sobre a identidade da função alvo (o conceito que está sendo aprendido).
- **Origem:** Geralmente, *H* é determinado pela escolha de representação feita pelo projetista humano do algoritmo. Ao escolher uma representação (como funções lineares, árvores de decisão ou redes neurais), o projetista define implicitamente o espaço de todas as hipóteses que o programa poderá representar e, portanto, aprender.

Avaliando Hipóteses com NumPy

Imagine que você é o projetista de um sistema de Aprendizado de Máquina para um filtro de Spam.

Tarefa (T): Classificar e-mails como "Spam" (1) ou "Não Spam"

Experiência (E): Um conjunto de dados contendo as etiquetas reais de 1 milhão de e-mails.

Medida de Desempenho (P): O Erro de Amostra, definido como a fração de exemplos classificados incorretamente.

Espaço de Hipóteses (H): contém dois modelos simplificados (h_1 e h_2) que já geraram suas previsões.

Objetivo: Utilize a biblioteca NumPy para calcular o Erro de Amostra de cada hipótese de forma vetorizada e determine qual delas generaliza melhor.

```python
import numpy as np

# Gerando 1 milhão de rótulos reais (0 ou 1)
y_real = np.random.randint(0, 2, size=1000000)

# Simulando as previsões de duas hipóteses h1 e h2 pertencentes a H
h1_preds = np.random.randint(0, 2, size=1000000)
h2_preds = np.random.randint(0, 2, size=1000000)

def calcular_erro_amostra(y_true, y_pred):
    # Vetorização: compara todos os elementos de uma vez
    erros = (y_true != y_pred)
    return np.mean(erros) # Retorna a fração de erros (P)

erro_h1 = calcular_erro_amostra(y_real, h1_preds)
erro_h2 = calcular_erro_amostra(y_real, h2_preds)

print(f"Desempenho P (Erro) da Hipótese h1: {erro_h1:.4f}")
print(f"Desempenho P (Erro) da Hipótese h2: {erro_h2:.4f}")
```

```
Desempenho P (Erro) da Hipótese h1: 0.5006
Desempenho P (Erro) da Hipótese h2: 0.4999
```