Álgebra Linear

O básico para entender como algoritmos aprendem

Espaços vetoriais

- Estrutura fundamental onde os objetos podem ser somados e multiplicados por escalares

- Os objetos devem permanecer dentro do mesmo conjunto

- **Definição formal:** Um espaço vetorial real $V=(v,+,\cdot)$ é um conjunto v com duas operações: adição e multiplicação por escalar. Ele deve satisfazer oito axiomas

Espaços vetoriais - Propriedades de adição

- **Comutatividade:** A ordem da soma não importa. $x + y = y + x$
- **Associatividade:** O agrupamento da soma não altera o resultado. $x + (y + z) = (x + y) + z$
- **Vetor zero (elemento neutro):** Existe um vetor único tal que, para qualquer vetor x, a soma $x + 0 = x$. Todo espaço deve conter esse vetor
- **Inverso Aditivo:** Para cada vetor x, existe um vetor único -x tal que $x + (-x) = 0$

Espaços vetoriais - Propriedades de Multiplicação por escalar

- **Identidade:** Multiplicar qualquer vetor x por 1 resulta no próprio x ($1 \cdot x = x$)

- **Associatividade da multiplicação:** Multiplicar pelos escalares c_1 e c_2 sequencialmente é o mesmo que multiplicar pelo produto deles. $(c_1c_2)x = c_1(c_2x)$

- **Distributividade:**

  - **Escalar sobre soma de vetores:** $c(x + y) = cx + cy$

  - **Vetor sobre soma de escalares:** $(c_1 + c_2)x = c_1x + c_2x$

Espaços vetoriais

- Além dos oito axiomas existe uma ideia central resumida no conceito de fechamento

- As operações de adição e multiplicação devem produzir resultados que permanecem dentro do espaço

- Se somarmos dois vetores o resultado deve estar dentro do espaço

- Se multiplicarmos um vetor por qualquer escalar o resultado deve permanecer dentro do espaço

Exemplos

- **R^n**: O espaço de todos os vetores coluna com n componentes reais.

- **Matrizes:** O espaço $R^{m \times n}$ de todas as matrizes $m \times n$.

- **Funções:** O espaço de funções (como polinômios) também pode ser tratado como um espaço vetorial.

- **Espaço Z:** O menor espaço vetorial possível, contendo apenas o vetor zero

Visualização dos Axiomas de Espaço Vetorial em R^2

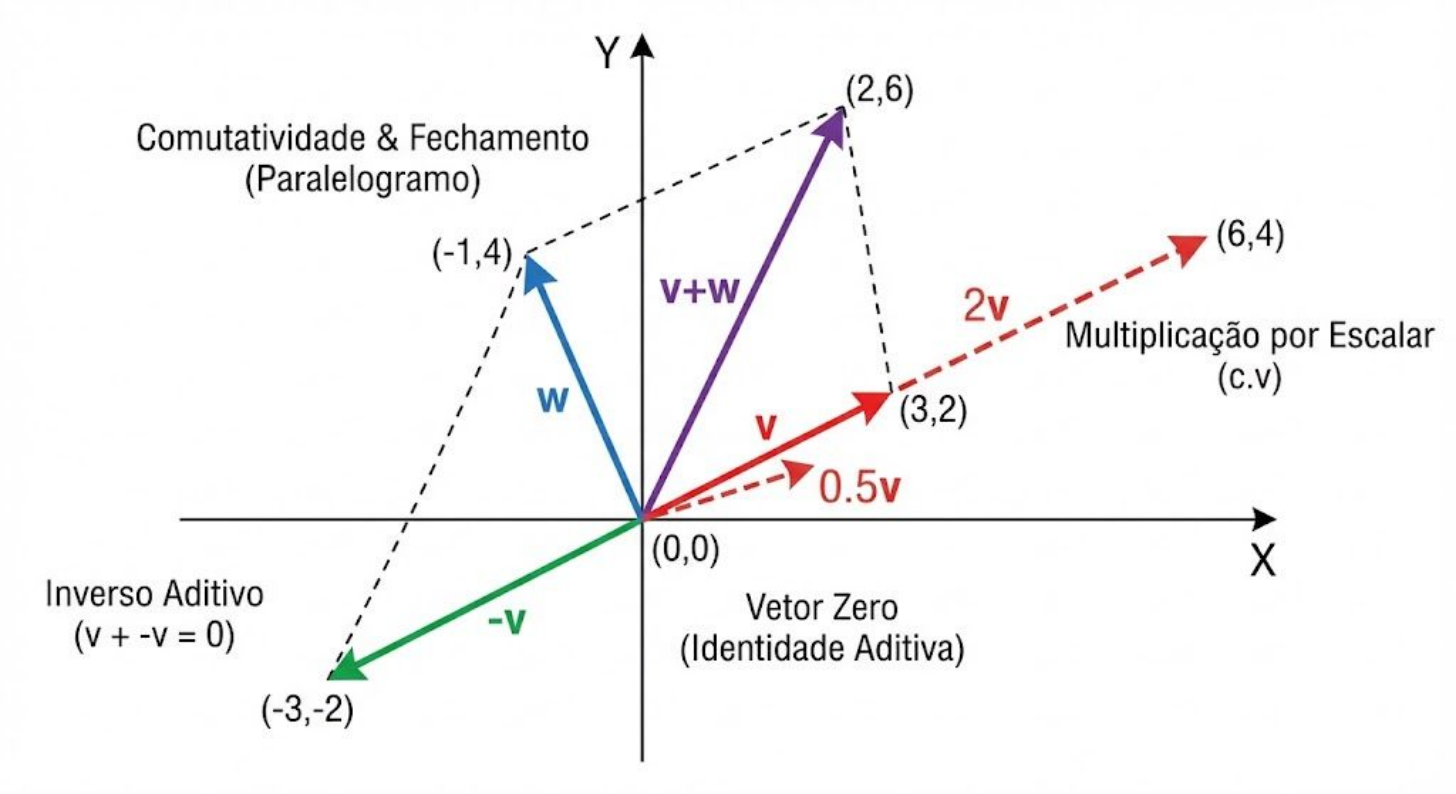

Subespaços vetoriais

- Conjunto de vetores dentro de um espaço maior
- O conjunto deve ser fechado
- Todo subespaço deve conter o vetor zero
- **Espaço Coluna (C(A)):** É um subespaço fundamental criado por todas as combinações lineares das colunas de uma matriz A. Resolver $Ax = b$ só é possível se o vetor v estiver no espaço coluna de A

Subespaços vetoriais

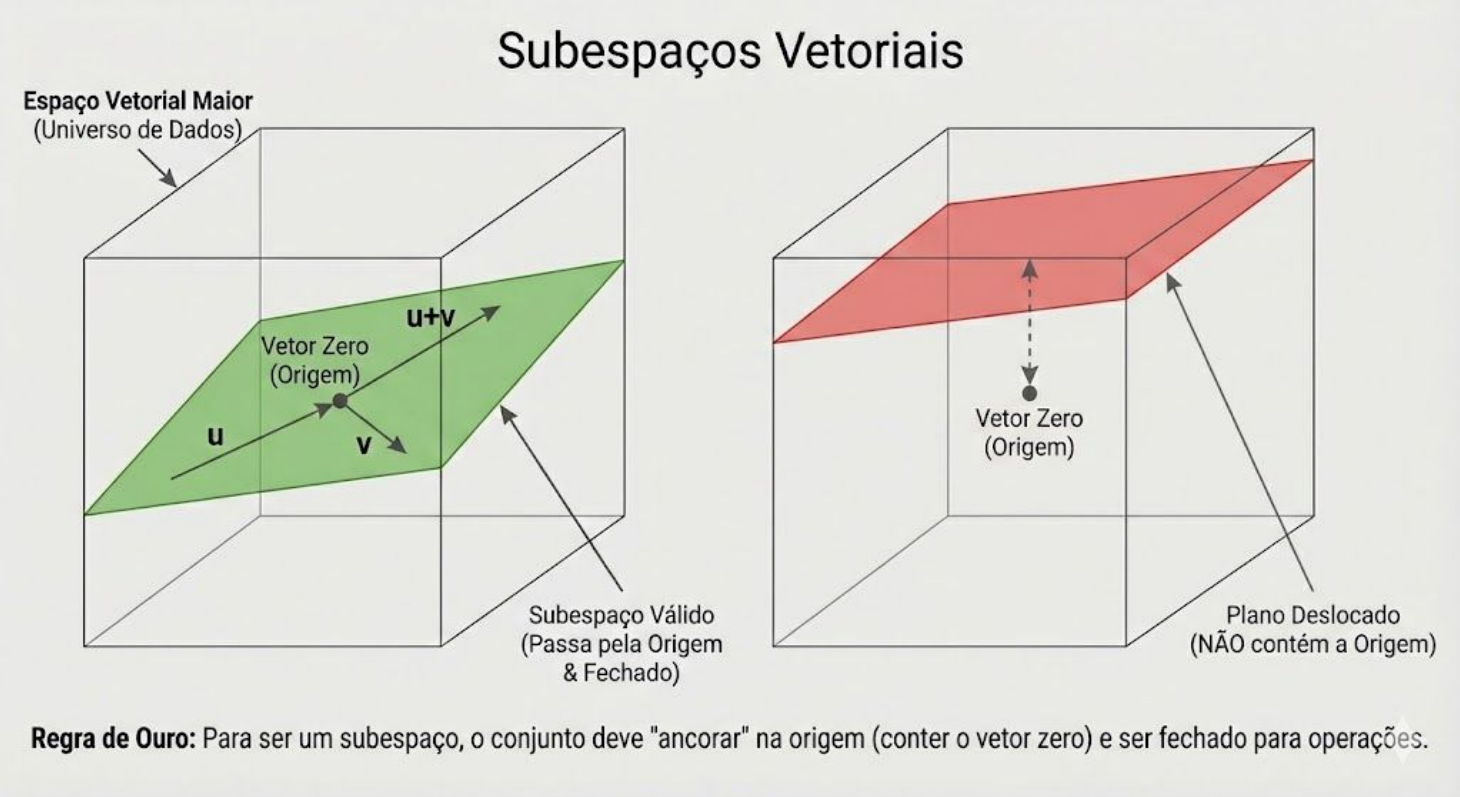

Subespaços vetoriais

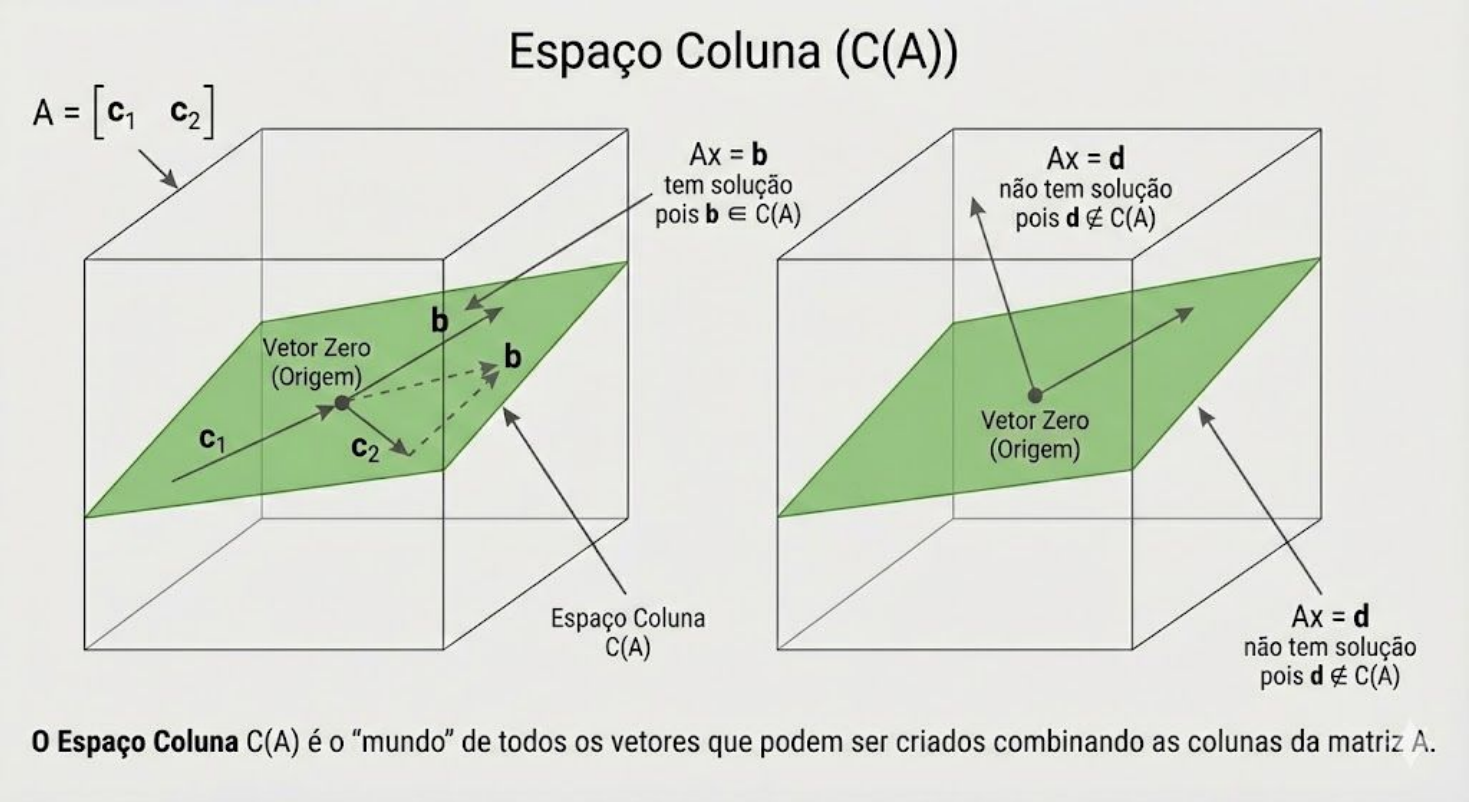

Espaços e AM

- Dados são tratados como vetores

- Uma tabela de dados é uma matriz
  - Linhas são exemplos (indivíduos)

  - Colunas são características (features)

- Como os dados são definidos como parte de um espaço vetorial (R^n onde n é o número de características) é possível calcular distância entre dois exemplos ou o ângulo entre eles.

- Essas ferramentas auxiliam a entender similares e aprender a responder a algo com base em exemplos.

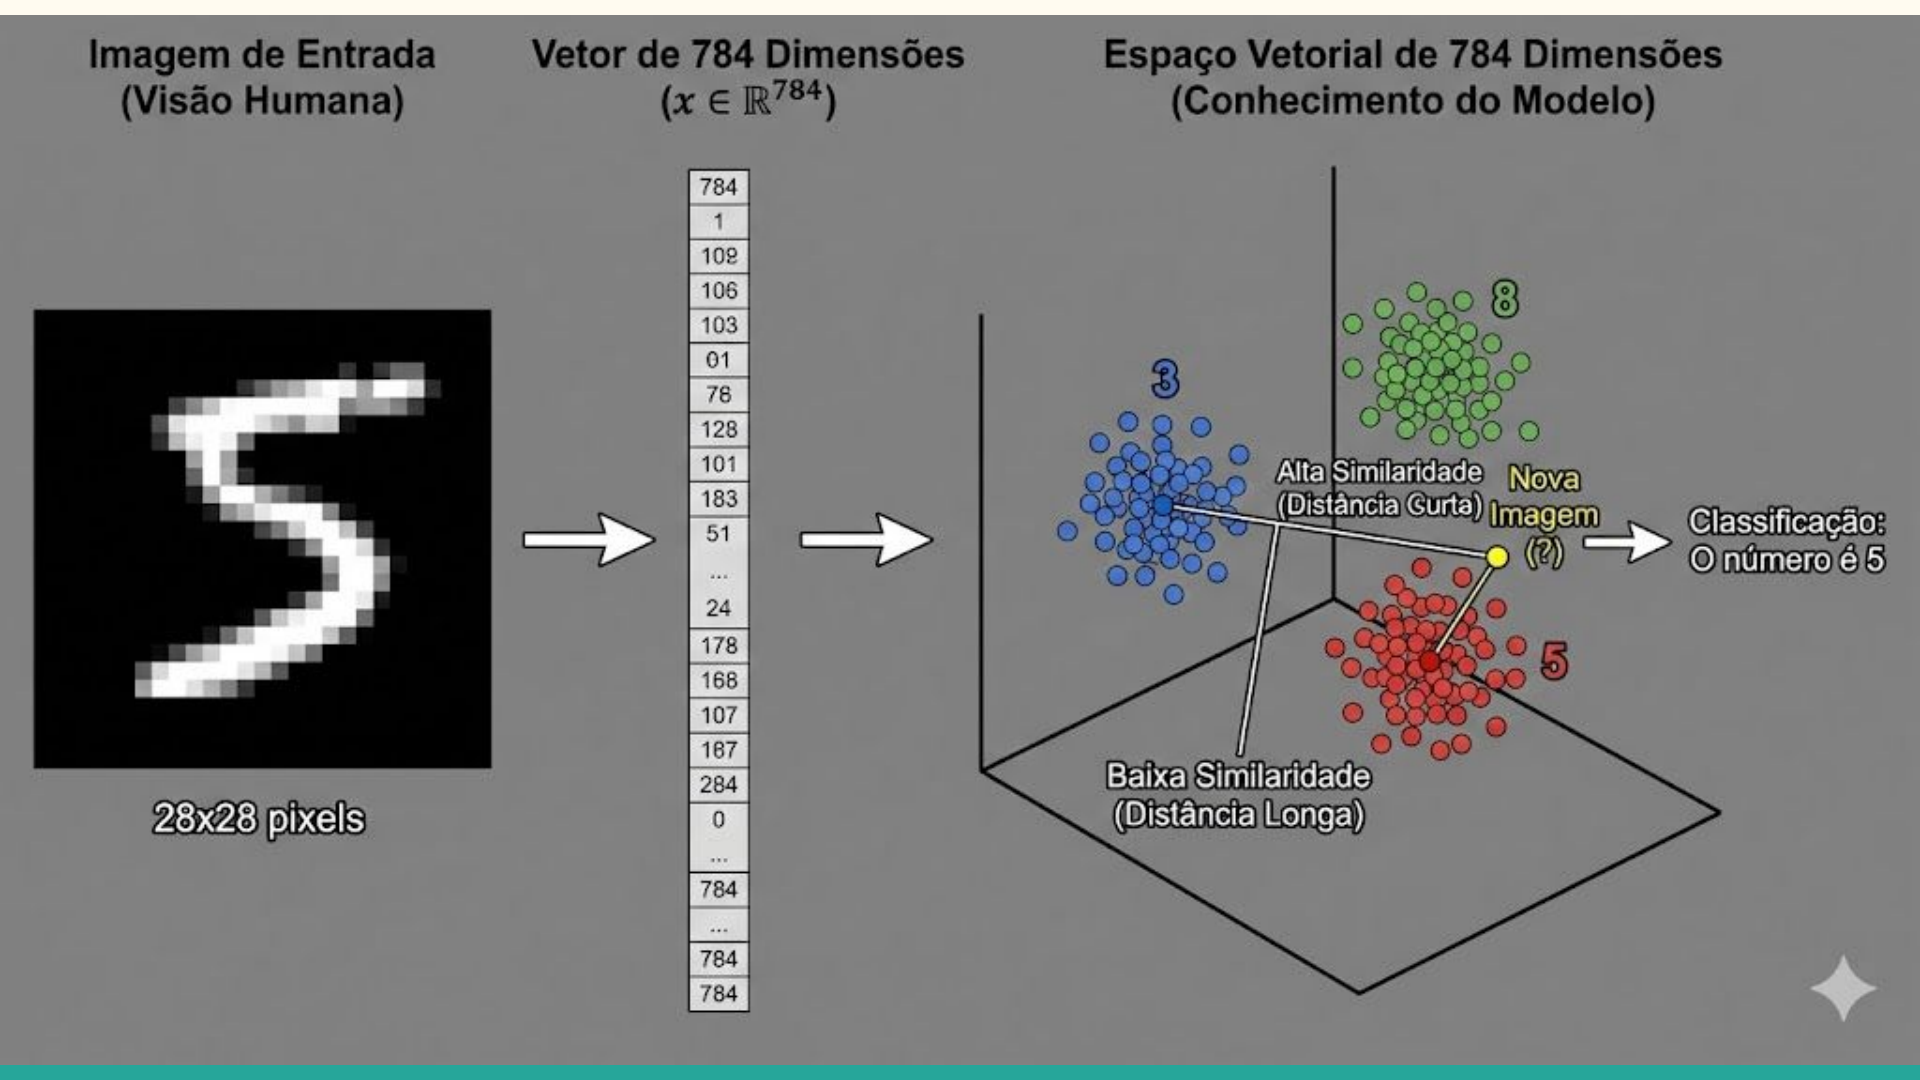
Imagem de Entrada
(Visão Humana)
28x28 pixels
Vetor de 784 Dimensões
($x \in \mathbb{R}^{784}$)
784
1
109
106
103
01
78
128
101
183
51
...
24
178
168
107
167
284
0
...
784
...
784
784
Espaço Vetorial de 784 Dimensões
(Conhecimento do Modelo)
3
8
5
Alta Similaridade
(Distância Curta)
Nova
Imagem
(?)
Baixa Similaridade
(Distância Longa)
Classificação:
O número é 5

Espaços afins

- Um subespaço vetorial que foi deslocado da origem

- **Definição formal:** Dado um espaço vetorial V, um vetor de deslocamento $x_0 \in V$ e um subespaço linear $U \subseteq V$, um subespaço linear afim L é definido como o conjunto:

$$L = x_0 + U = \{x_0 + u \mid u \in U\}$$

- sendo U o espaço de direção e x_0 o ponto de suporte

Espaços afins

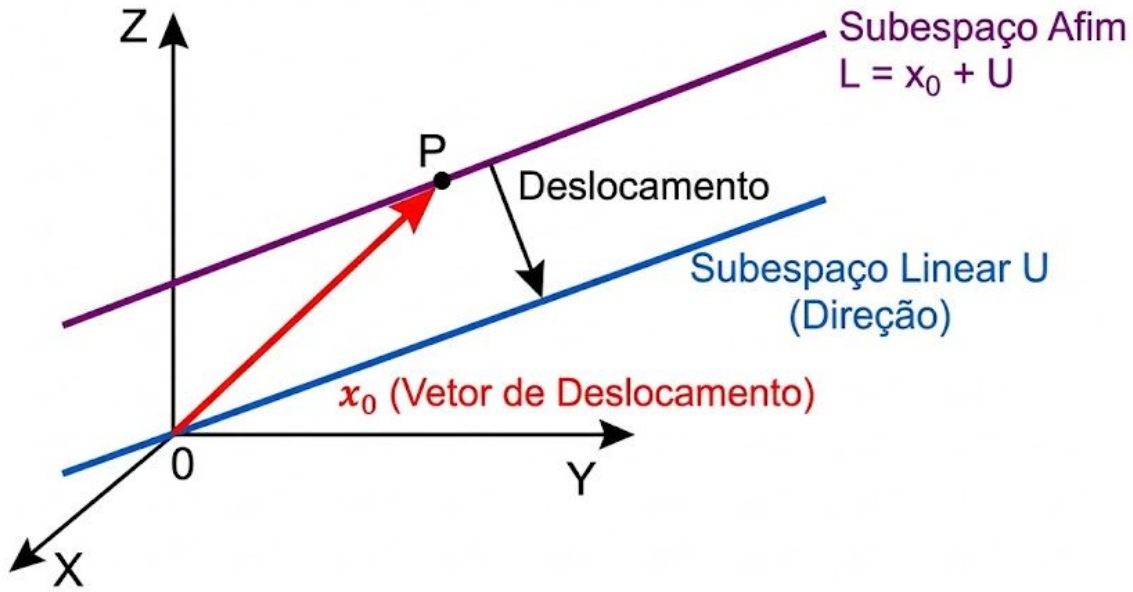

$L = x_0 + U$: Um subespaço afim L é um subespaço linear U deslocado pelo vetor x_0.

Hiperplano

- É um tipo específico de espaço afim
- **Definição:** Em um espaço vetorial de dimensão D, um hiperplano é um subespaço afim de dimensão D - 1
  - Em 2D (R^2), um hiperplano é uma linha
  - Em 3D (R^3), um hiperplano é um plano comum
- Normalmente é definido por sua equação e vetor normal:

$$\langle w,x\rangle + b = 0$$

- w é o vetor normal, ou seja, um vetor perpendicular a qualquer vetor que esteja sobre o hiperplano. Ele define a orientação
- b é o intercepto, que é a distância do hiperplano até a origem. Se $b = 0$ o hiperplano passa pela origem

Hiperplano

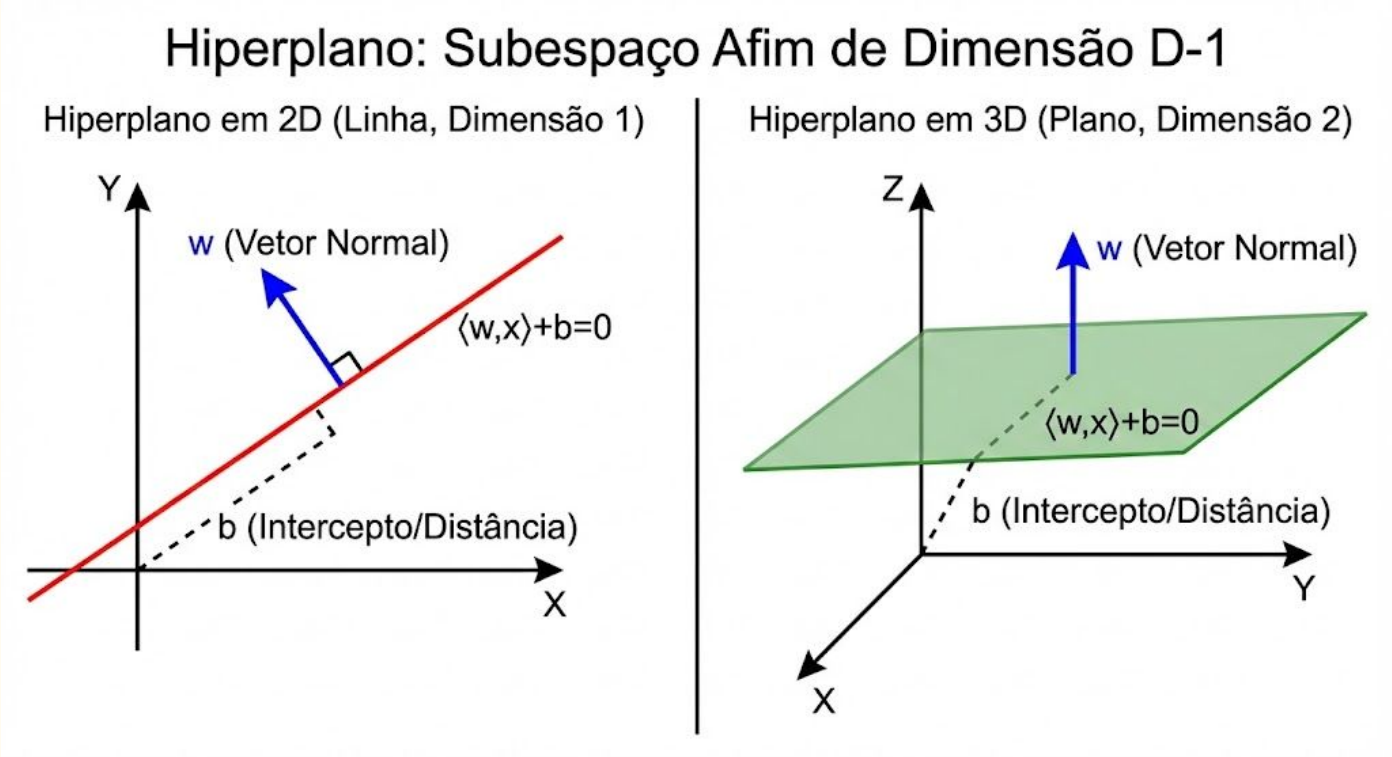
Hiperplano: Subespaço Afim de Dimensão D-1
Hiperplano em 2D (Linha, Dimensão 1)
Y
w (Vetor Normal)
⟨w,x⟩+b=0
b (Intercepto/Distância)
X
Hiperplano em 3D (Plano, Dimensão 2)
Z
w (Vetor Normal)
⟨w,x⟩+b=0
b (Intercepto/Distância)
Y
X

Hiperplano

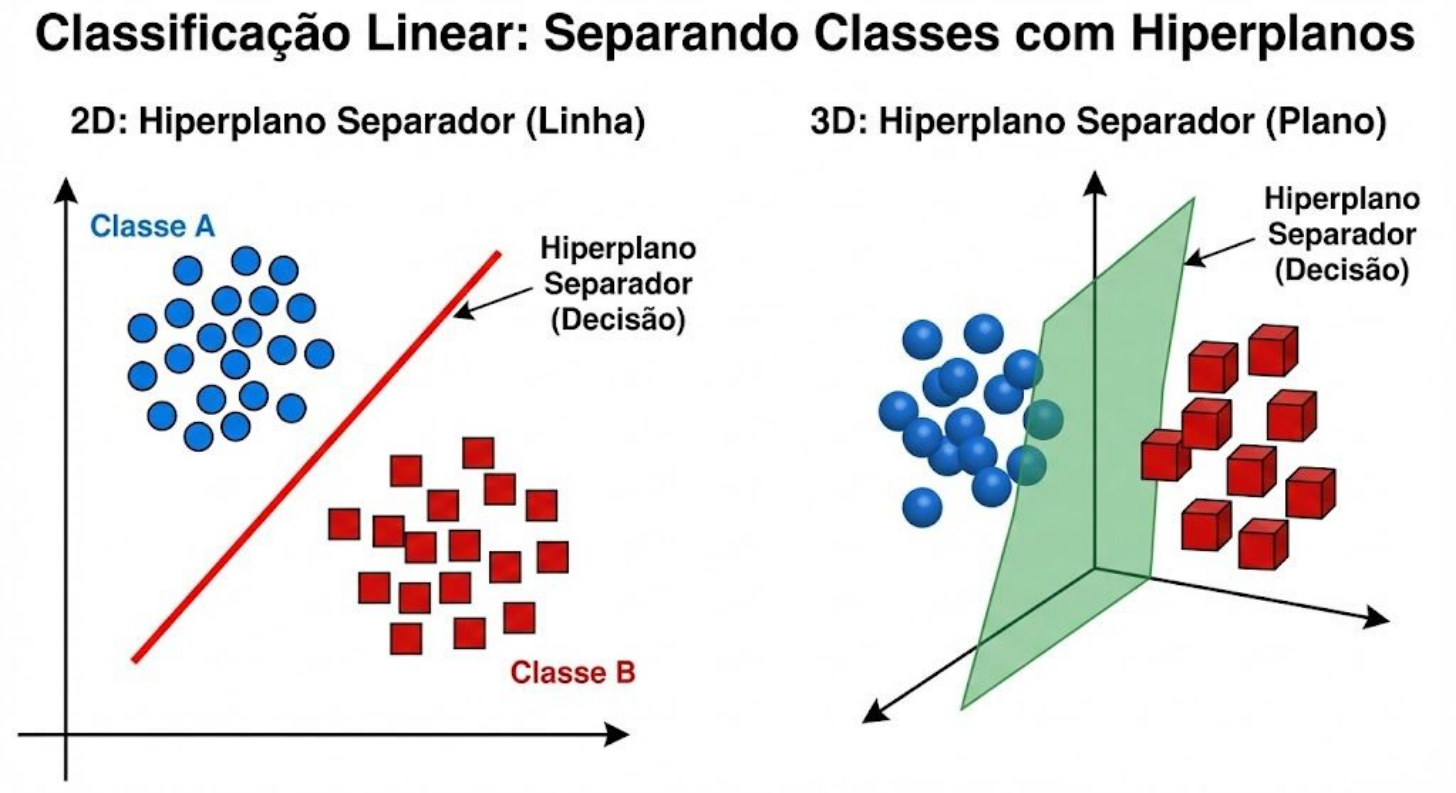
Classificação Linear: Separando Classes com Hiperplanos
2D: Hiperplano Separador (Linha)
3D: Hiperplano Separador (Plano)
Classe A
Hiperplano Separador (Decisão)
Classe B
Hiperplano Separador (Decisão)

Normas

- Norma é uma função que atribui um comprimento a um vetor

- Intuitivamente mede a distância da ponta do vetor até a origem

- **Propriedades da norma:** Uma norma $||\cdot||$ deve satisfazer três condições: ser absolutamente homogênea ($||\lambda x||=|\lambda|\,||x||$), satisfazer a desigualdade triangular ($||x+y||\leq||x||+||y||$) e ser positiva definida ($||x||=0\Leftrightarrow x=0$)

Norma Euclidiana (L_2)

- Norma padrão usada em geometria
- Para um vetor $x \in R^n$ é definida como a raiz quadrada da soma dos quadrados dos componentes

$$\|x\|_2 = \sqrt{\sum x_i^2} = \sqrt{x^T x}$$

- Ela representa a distância física (um segmento de reta) da origem até o ponto x

Norma Manhattan (L_1)

- É a soma dos valores absolutos dos componentes do vetor

$$\|x\|_1 = \sum |x_i|$$

- A norma L_1 é frequentemente usada em AM para incentivar soluções esparsas

Normas

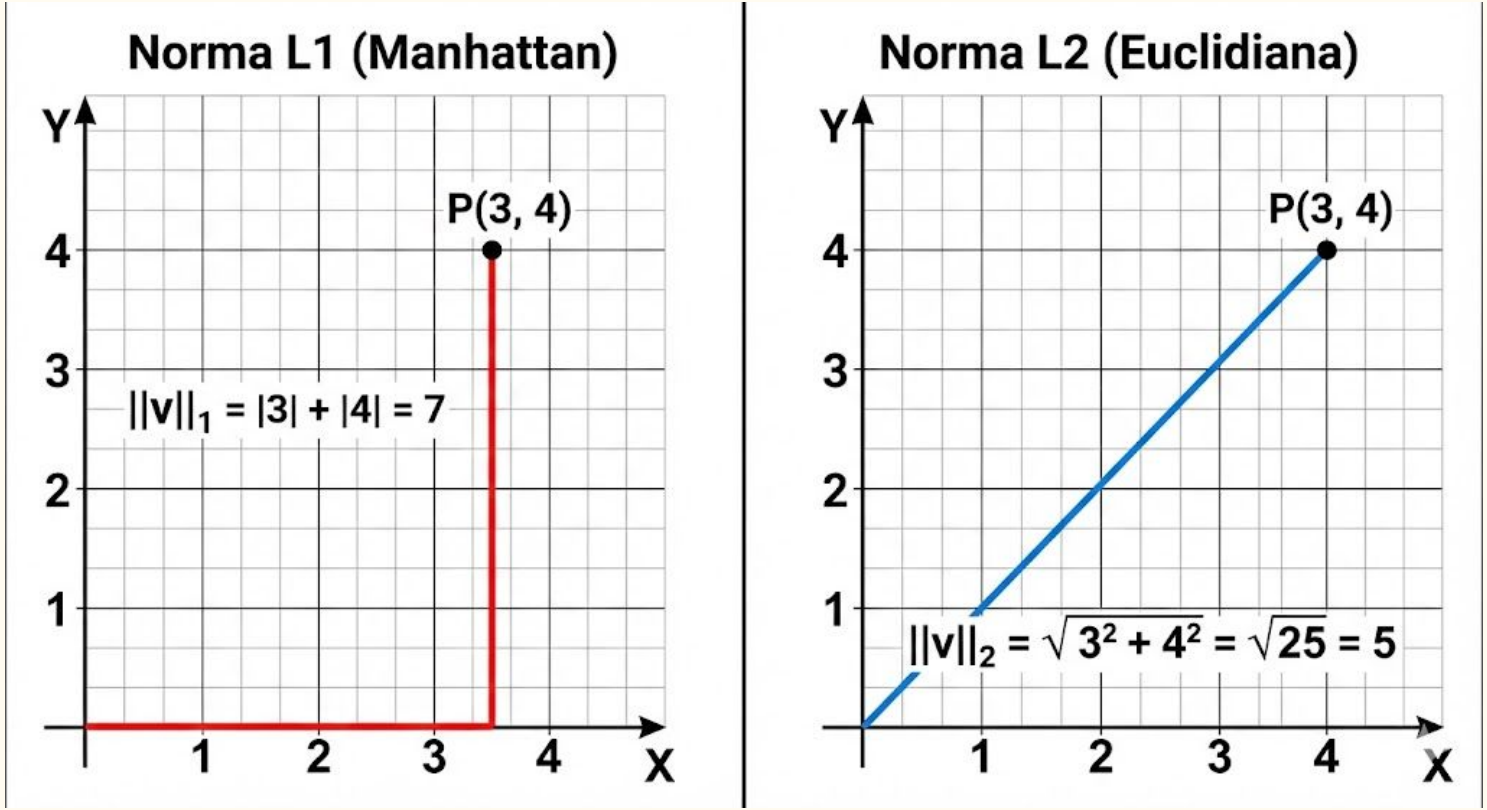
Norma L1 (Manhattan)
Y
P(3, 4)
4
3
2
1
||v||1 = |3| + |4| = 7
1
2
3
4
X
Norma L2 (Euclidiana)
Y
P(3, 4)
4
3
2
1
||v||2 = √ 3² + 4² = √25 = 5
1
2
3
4
X

Produto interno

- **Definição geral:** É um mapeamento bilinear $\Omega: V \times V \to R$ que é simétrico $\langle x,y \rangle = \langle y,x \rangle$) e positivo definido ($\langle x,x \rangle > 0$ para x diferente de 0)
- **Produto escalar:** Para vetores v e w é calculado como $v \cdot w = \sum v_i w_i$ ou, em notação matricial, $v^T w$
- **Geometria e ortogonalidade:**
  - **Comprimento:** O produto interno induz uma norma $\|x\| = \sqrt{\langle x, x \rangle}$
  - **Ângulo:** O cosseno do ângulo θ entre dois vetores é dado por $\cos\theta = \frac{\langle x,y \rangle}{\|x\|\|y\|}$
  - **Ortogonalidade:** Dois vetores são ortogonais (perpendiculares) se o seu produto interno for zero

$$\langle x, y \rangle = 0 \iff x \perp y$$

Produto interno

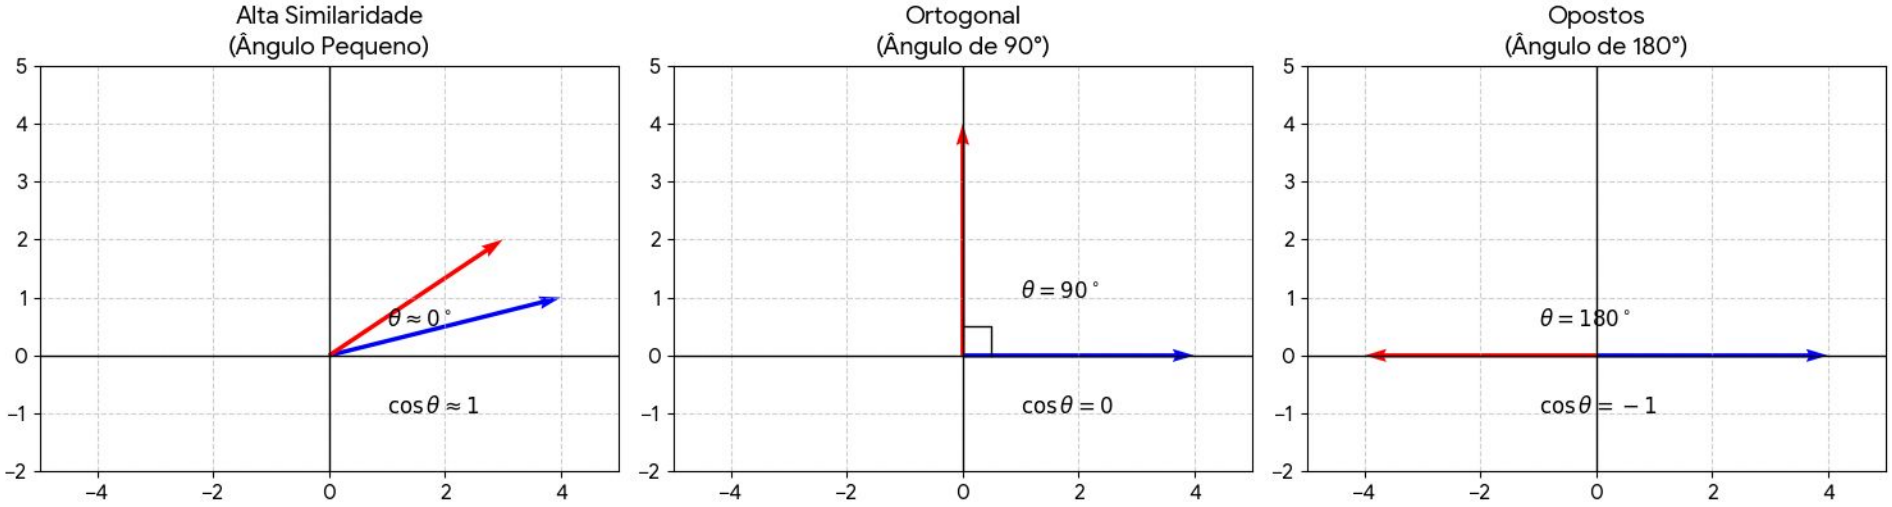

Projeções

- As projeções são transformações lineares fundamentais, usadas para encontrar o vetor em um subespaço que esteja mais próximo de um vetor original
- **Projeção em uma linha:** Ao projetar um vetor b sobre uma linha definida pelo vetor a utilizamos a fórmula → $p = \frac{\langle a,b \rangle}{\langle a,a \rangle} a$
- **Matriz de Projeção:** Para uma linha → $P = \frac{aa^T}{a^T a}$
  - P é simétrica ($P^T = P$) e idempotente ($P^2 = P$)
- **Projeção em um subespaço:** Para projetar b em um subespaço de dimensão maior é utilizada a condição de erro b - Ax deve ser ortogonal a todo subespaço.
- **Matriz de projeção:** $P = A(A^T A)^{-1} A^T$
  - A projeção é $p = Pb$

Similaridade no Espaço R^{784}

Como vimos, uma imagem de 28 X 28 pixels é um vetor $x \in R^{784}$. Teoricamente, dois desenhos do número 5 devem ser mais similares entre si do que um 5 e um 0.

Implemente a função de similaridade do cosseno e teste a hipótese geométrica

Questões para reflexão

Impacto do Escalar: Se multiplicarmos todos os pixels de uma imagem por um escalar $c=2$ (aumentando o brilho), a similaridade de cosseno com a imagem original muda? Por que a norma L_2 mudaria, mas o ângulo não?.

Ortogonalidade: Se encontrarmos uma similaridade próxima de zero entre dois dígitos diferentes, o que isso significa geometricamente sobre a independência desses dados?

Decisão via Hiperplano: Como poderíamos usar um hiperplano para separar os vetores que têm alta similaridade com o dígito 5 daqueles que têm baixa similaridade?