Funções de perda e otimização

Como aprender algo

Otimização

- Treinar modelos de aprendizado de máquina é um problema de otimização contínua
- Objetivo é encontrar um conjunto de parâmetros que expliquem os dados
- Isso é formulado com a minimização de uma função de Loss
- Uma função de Loss é uma função que, dada a predição do modelo e o dado real, ela mensura a quantidade de perda que a predição do modelo traz

Função de Loss

- Função de Loss (L ou ℓ) → É uma função que recebe o rótulo verdadeiro (ground truth) de um dado e a predição feita pelo modelo, produzindo um número não-negativo que representa o erro cometido nessa predição em particular

- Exemplos:
  - Mean Squared Error (MSE → tradicional para regressão):
  - Cross Entropy (CE → tradicional para classificação):

$$J(\theta) = \frac{1}{n} \sum_{i=1}^{n} (h_\theta(x^{(i)}) - y^{(i)})^2$$

$$L = -\sum_{c=1}^{C} y_c \log(\hat{y}_c)$$

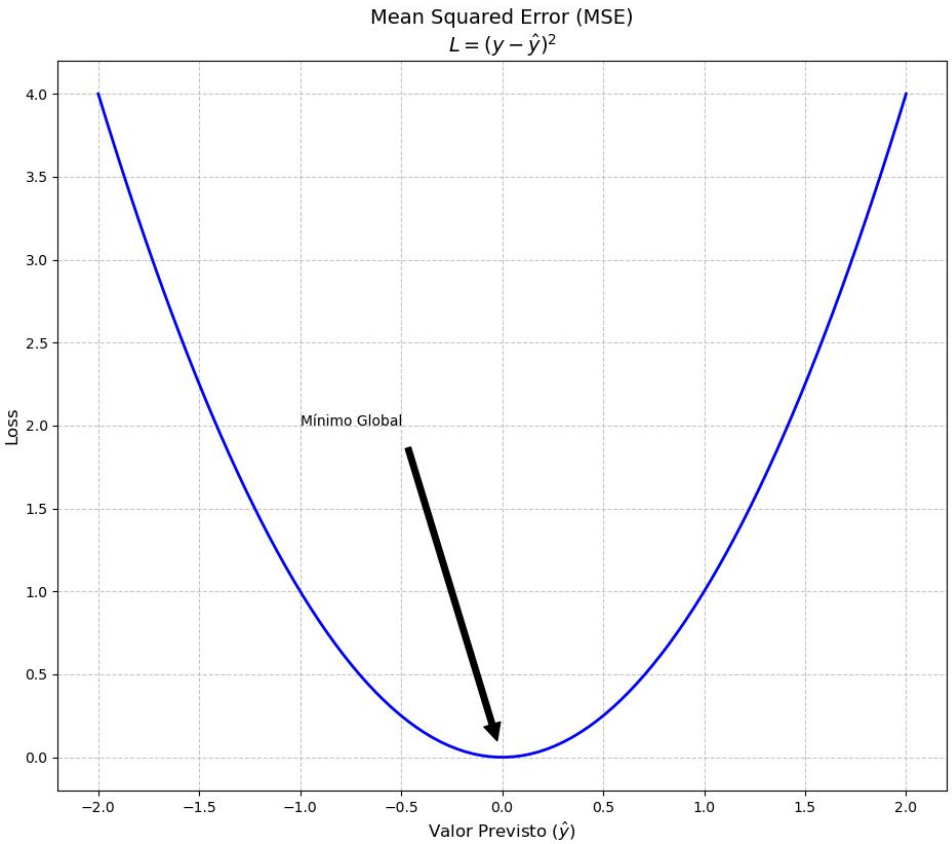
Mean Squared Error (MSE)
$L = (y - \hat{y})^2$
Mínimo Global
Loss
Valor Previsto ($\hat{y}$)
4.0
3.5
3.0
2.5
2.0
1.5
1.0
0.5
0.0
−2.0
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5
2.0

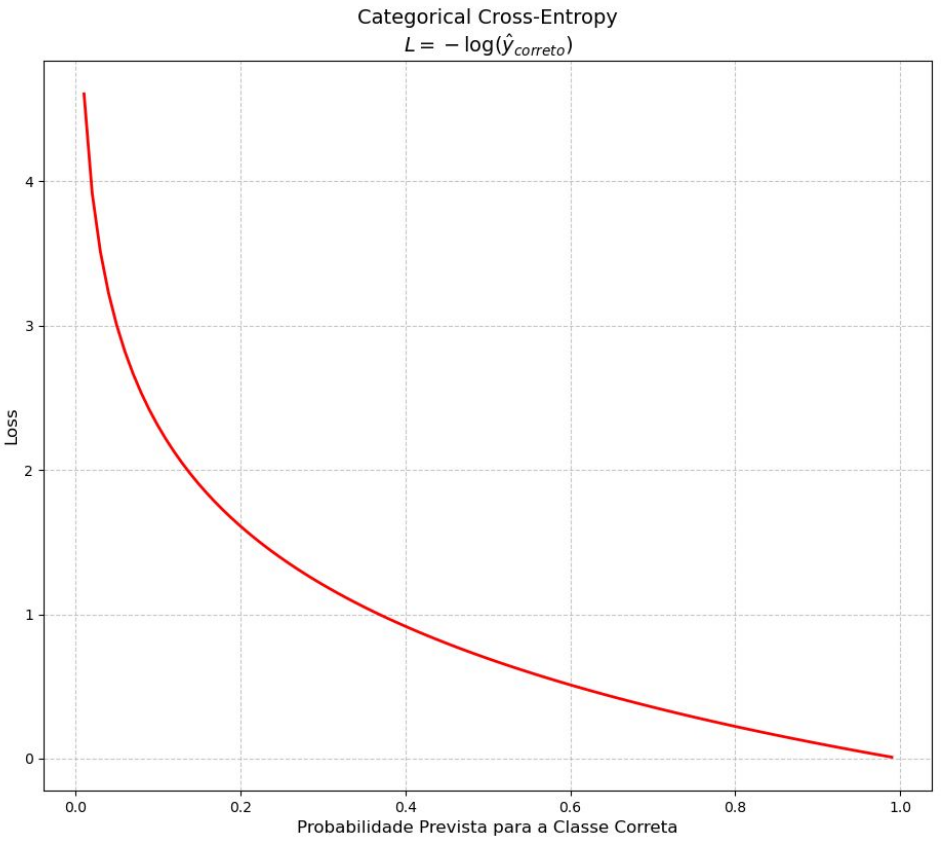
Categorical Cross-Entropy
$L = -\log(\hat{y}_{correto})$
Loss
Probabilidade Prevista para a Classe Correta
4
3
2
1
0
0.0
0.2
0.4
0.6
0.8
1.0

Funções concavas e convexas

- Uma função é convexa se ela tiver o formato de uma tigela ou um "U" voltado para cima. Em Aprendizado de Máquina, funções de perda convexas (como o MSE) porque elas garantem a convergência e, portanto, são preferidas.

- Uma função é côncava se ela tiver o formato de uma montanha ou um "U" invertido. É essencialmente o oposto da função convexa.

A Segurança da Convexidade

Em funções convexas, todo mínimo local é também um mínimo global.

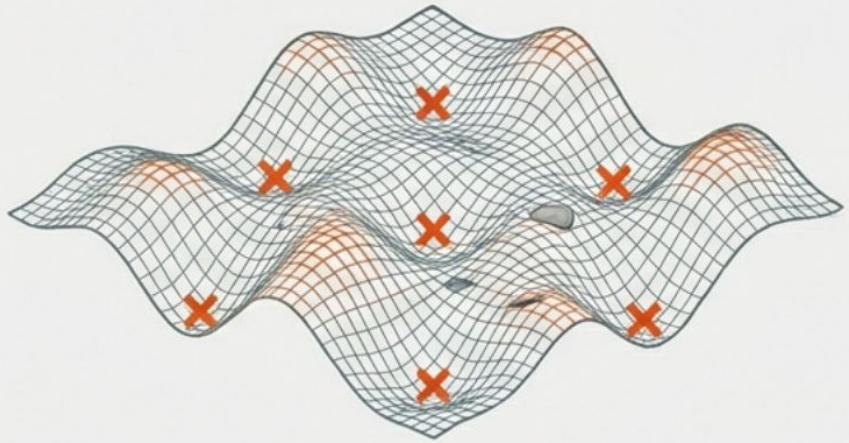

Não-Convexo: Armadilhas e Mínimos Locais

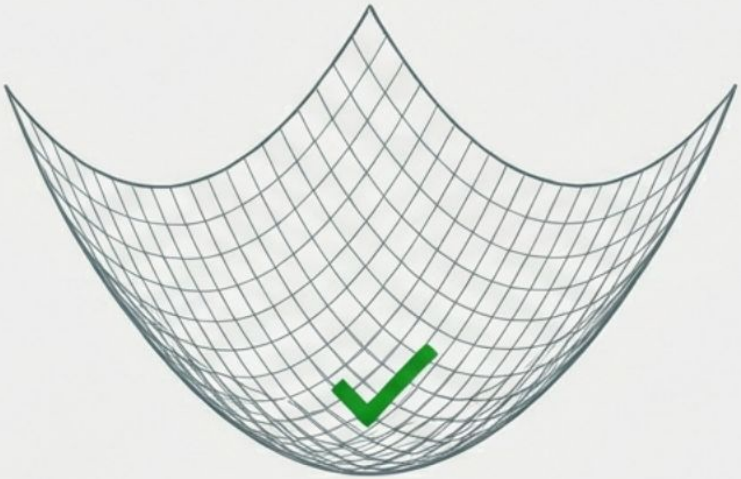

Convexo: Garantia Global

Comparação

Característica	Função Convexa	Função Côncava
Formato Visual	Tigela	Montanha
Ponto Crítico	Mínimo Global	Máximo Global
Plano Tangente	Subestimador Global (fica abaixo)	Superestimador Global (fica acima)

Otimização

- O ideal seria minimizar o erro para os dados futuros
- Impossível realizar, pois não temos acesso aos dados futuros
- Então a otimização é feita levando em consideração o risco empírico
  - A média do loss em todos os exemplo de treinamento

Como otimizar?

- Necessário de informações da derivada das funções
- O Gradiente (∇f): É a generalização da derivada para funções multivariadas. O gradiente é um vetor que aponta na direção da subida mais íngreme (steepest ascent) da função. Por analogia, se você está em um vale, o gradiente aponta para o topo da montanha.
    - É a velocidade da subida
- Matriz Hessiana ($\nabla^2 f$): É a coleção de todas as derivadas parciais de segunda ordem de uma função multivariada. Enquanto o gradiente nos diz a inclinação da função, a Hessiana mede a curvatura da função localmente ao redor de um ponto.
    - É a aceleração

Hessiana e a Convexidade das Funções de Erro

- A convexidade é uma propriedade altamente desejável. Para funções convexas, não existem "armadilhas": todo mínimo local é também um mínimo global

- **Condição de Primeira Ordem:** Uma função diferenciável é convexa se, e somente se, a sua aproximação de Taylor de primeira ordem (baseada no gradiente) é um subestimador global da função.

- **Condição de Segunda Ordem (A Hessiana):** Uma função duas vezes diferenciável é convexa se e somente se o seu domínio é convexo e a sua Matriz Hessiana é positiva semidefinida ($\nabla^2 f(x) \geq 0$) para todos os pontos no domínio. Geometricamente, a exigência $\nabla^2 f(x) \geq 0$ significa que o gráfico da função tem curvatura positiva (voltada para cima) em x, como uma tigela.

- **Convexidade Estrita:** Se a Hessiana for positiva definida ($\nabla^2 f(x) > 0$) em todo o domínio, a função é estritamente convexa e possui um único ponto de mínimo global absoluto.

Condição de primeira ordem

- Imagine uma tigela (função convexa). Se você escolher qualquer ponto na superfície dessa tigela e encostar uma placa reta (um plano tangente), toda a tigela ficará acima dessa placa.
- **Subestimador Global:** Isso significa que a linha reta (ou plano) nunca ultrapassa o valor da função. Ela sempre "chuta" um valor menor ou igual ao real.
- **Por que isso é exclusivo da convexidade?**
- Se a função fosse côncava (uma montanha), o plano tangente estaria sempre acima dela (superestimador).
- Se a função fosse não-convexa (com altos e baixos), o plano tangente estaria abaixo em alguns pontos e acima em outros.

1. FUNÇÃO CONVEXA (UMA TIGELA): SUBESTIMADOR GLOBAL

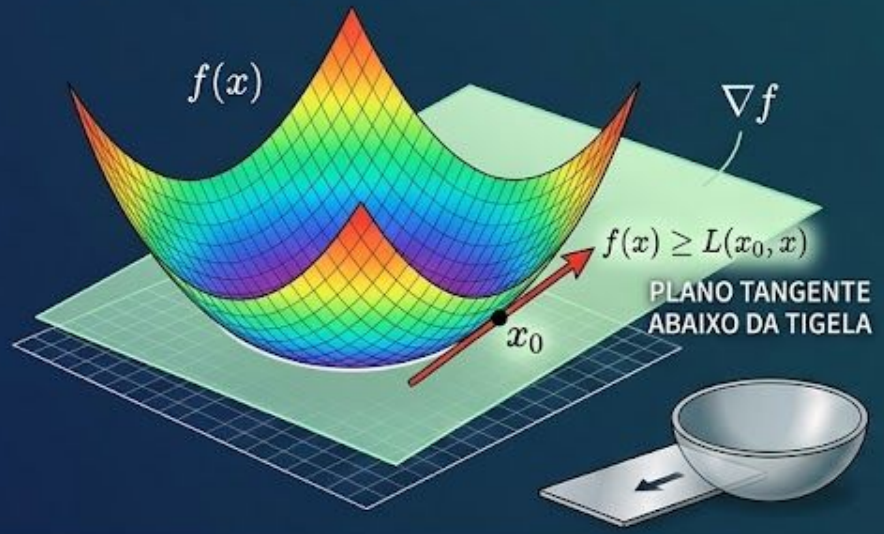

2. FUNÇÃO CÔNCAVA (UMA MONTANHA): SUPERESTIMADOR GLOBAL

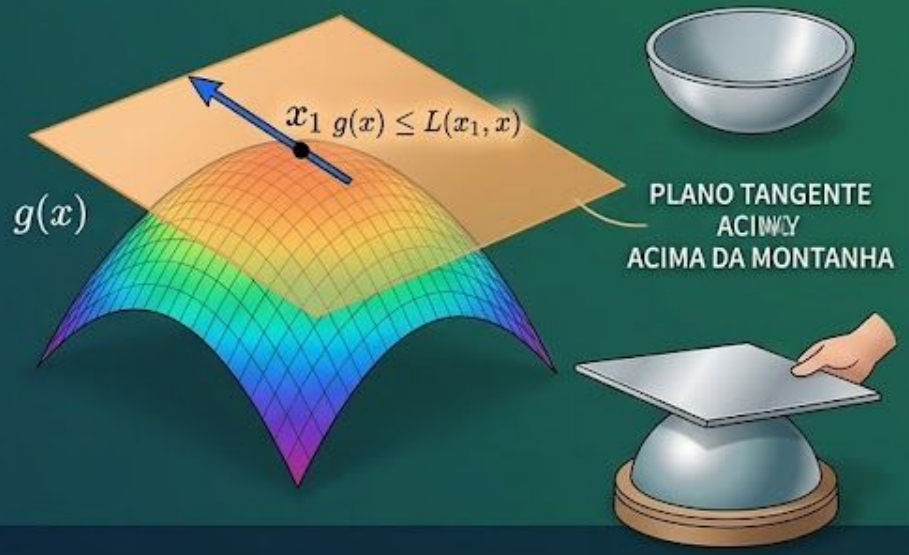

3. FUNÇÃO NÃO-CONVEXA (ALTOS E BAIXOS): LOCAL

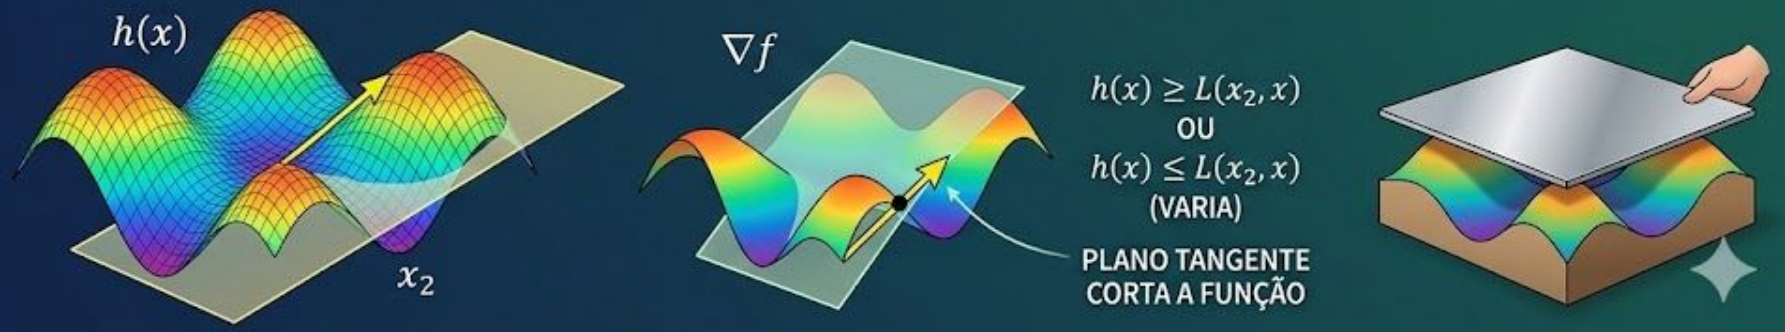

A Hessiana: Definindo a Curvatura do Terreno

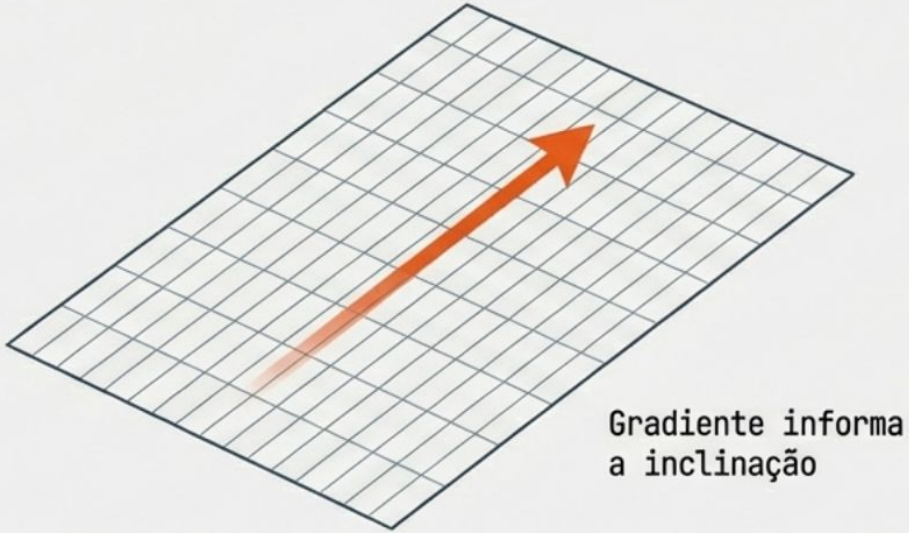

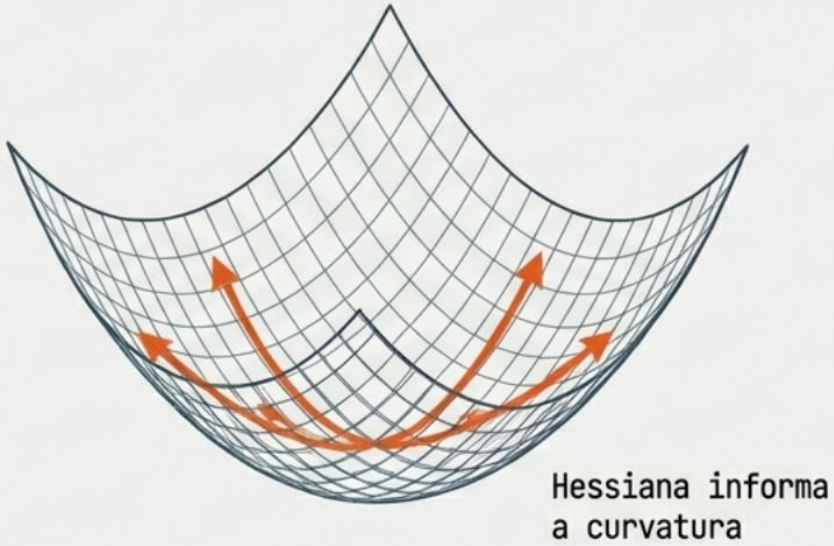

Implementação

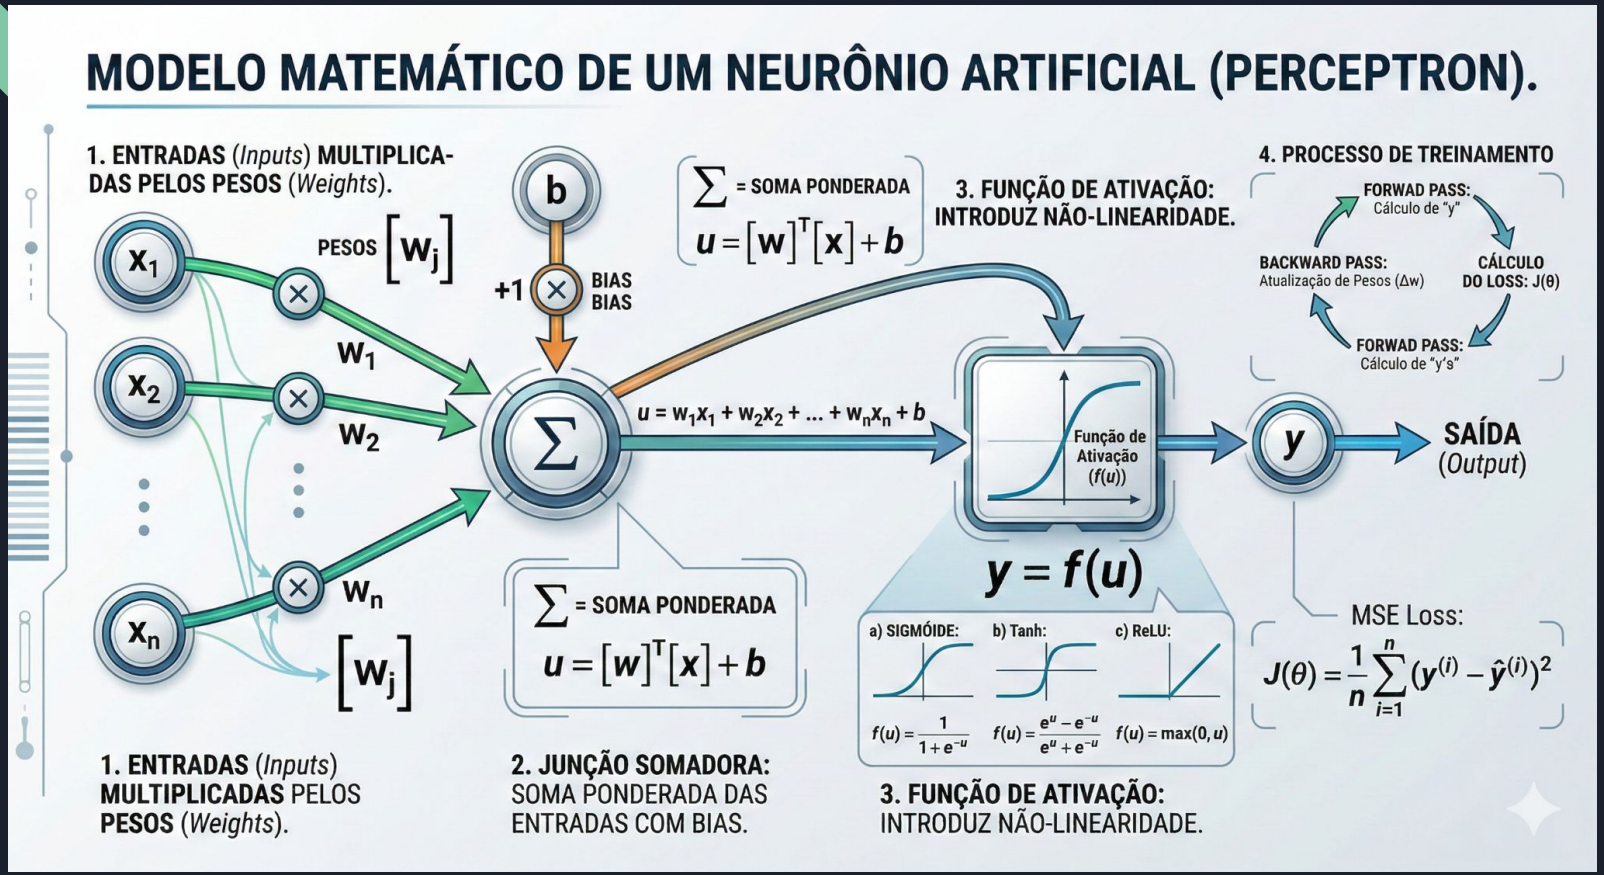

Gradiente descendente

- O Gradiente Descendente é um algoritmo de otimização de primeira ordem
- Intuitivamente, para encontrar o vale de uma função de perda, começamos em um ponto aleatório e damos passos na direção oposta à do gradiente (descida mais íngreme)

$$x_{i+1} = x_i - \gamma_i (\nabla f(x_i))^T$$

- Onde γ_i é a taxa de aprendizado

Gradiente descendente

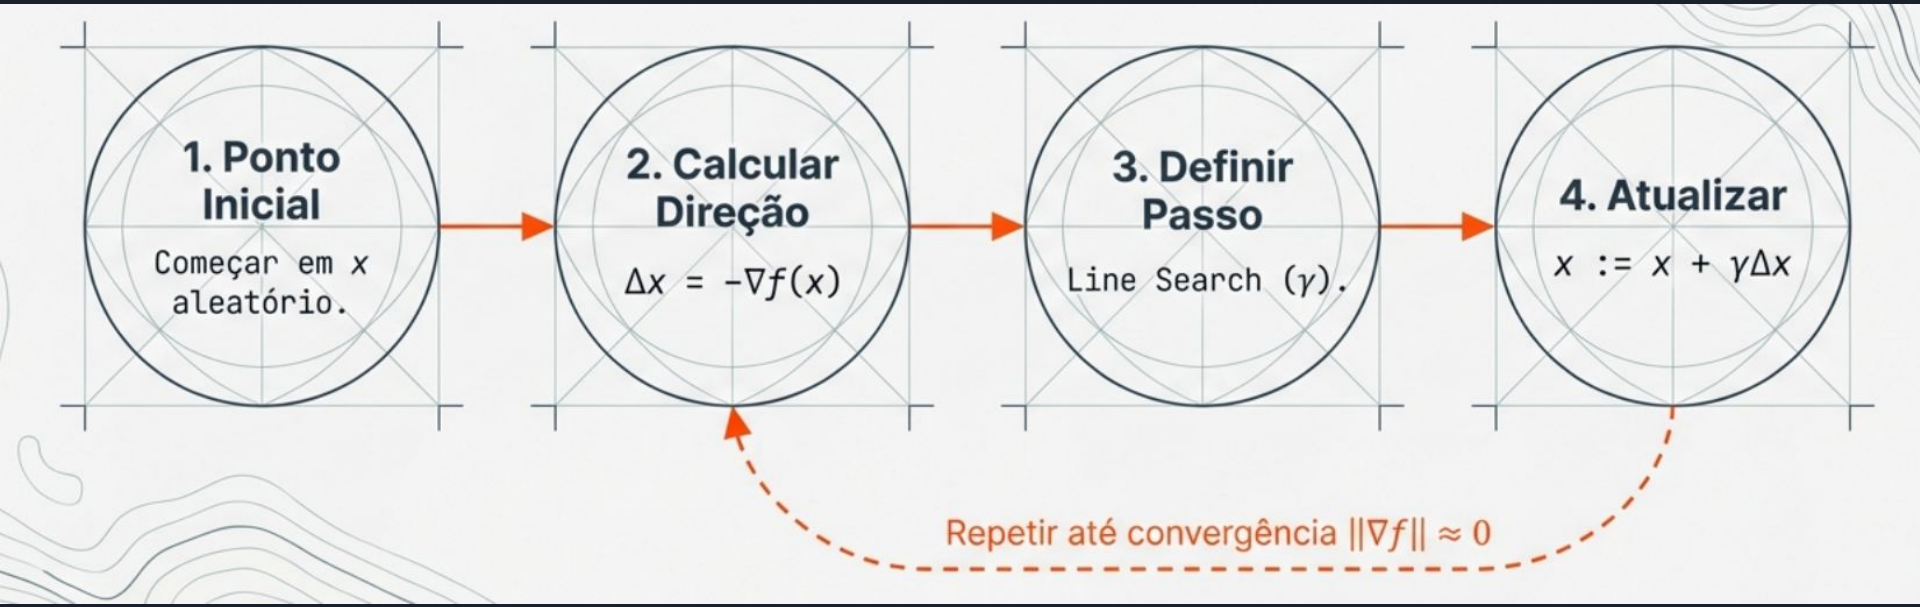

A regra de atualização

Onde estamos agora

Taxa de Aprendizado
(Passo)

$$x_{i+1} = x_i - \gamma_i(\nabla f(x_i))^T$$

Direção oposta à subida

O Gradiente
(Inclinação)

Implementação

Neuronio com Gradiente Descendente

Variações comuns

- **Momentum:** Introduz uma "memória" da direção do passo anterior. Ajuda a amortecer as oscilações ao longo de vales estreitos e acelera a convergência em superfícies achatadas

- **Gradiente Descendente Estocástico (SGD):** Em vez de calcular o gradiente somando os erros de todo o conjunto de dados de treinamento ("em lote" ou batch), calcula-se o gradiente com base num único exemplo (ou um pequeno mini-batch). Essa aproximação ruidosa, mas imparcial do gradiente, reduz drasticamente o custo computacional por iteração e é fundamental para treinamentos de aprendizado de máquina em larga escala (como redes neurais)