Redução de Dimensionalidade

PCA e outras técnicas

MNIST e o Neurônio

Tentar "achatar" as imagens e treinar um neurônio para aprender identificar números

Ao invés de um vetor de característica de duas dimensões será um de 784

Duas formas:

- Um neurônio aprende cada número e gera uma chance daquela entrada ser o número que ele aprendeu → Ativação com Sigmoide
- A saída ser o número aprendido → Ativação com ReLU

A mudança disso acarretará na mudança da função de ativação

APRENDIZADO DE NEURÔNIO MNIST COM ATIVAÇÃO ReLU

1. ENTRADA DE DADOS (IMAGENS MNIST)

28 x 28

28 x 28

784 ENTRADAS (X)
(CHASQUEADAS EM VETOR)

2. ARQUITETURA DO NEURÔNIO SIMPLES

784 entradas (X)

x_0, x_1, x_1, x_2, ⋮, x_{783}

w_0, w_1, w_2, ⋮, w_{783}

$$z = \sum_i (X_i * W_i) + bias$$

$z > 0$
Deriv. = 1

$z > 0$

$z \leq 0$

$f(z) = máx(0, z)$

Deriv. = 0
(Gradiente zero)

SAÍDA (ŷ)

Previsão
(e.g., 3.1)

784 entradas (X)

Update Weights

3. APRENDIZADO SUPERVISIONADO E PERDA

$\hat{y}$ VS

Previsão
($\hat{y}$)

Rótulo Real
= 3)

Medidor de Perda
(Erro Quadrático Médio)

$$EQM = \frac{1}{n} \sum_n (y - \hat{y})^2$$

4. CICLO DE TREINAMENTO E BACKPROPAGATION

Passagem Direta
(Previsão)

Passagem Inversa
(Fluxo de Gradiente)

Atualização de Pesos

$z \leq 0$
Deriv. =

$z > 0$

epocas = 100000
learningRate = 0.0001

Atualização de Pesos: Wi -= Learning Rate * wGrad
Bias -= Learning Rate * bGrad

epocas = 100000
learningRate = 0.0001

Problema da dimensionalidade

Será que é necessário a dimensão de tamanho 784 para aprender a distinguir entre os dígitos escritos?

Imagine que você tem um modelo em 3D de um objeto e precisa desenhar ele em uma folha em duas dimensões.

Necessário procurar o melhor ângulo que possibilite visualizar as características mais relevantes do objeto e, ao fazer seu desenho em duas dimensões, ele mantém as características primordiais do objeto

Essa redução de dimensão é conhecida como **projeção**

Análise dos Componentes Principais (PCA)

Análise de Componentes Principais (PCA) é uma técnica para a redução de dimensionalidade, compressão de dados e extração de características

Foca em manter os componentes do dado que possuem maior variabilidade e, assim, mantendo a discriminalidade dos dados

A variância de um componente diz muito sobre sua discriminabilidade

> **Caso A:** Uma sala possui todos os alunos com a mesma altura. Esse dado não é relevante para identificar alunos
>
> **Caso B:** Existe uma variação de alturas entre 1.5m e 2.03m. Essa variação das alturas pode ser relevante para identificar um aluno

Análise dos Componentes Principais (PCA)

O primeiro passo no PCA é padronizar os dados.

A média de cada variável (ou linha de medições) é calculada e subtraída dos dados originais, garantindo que o conjunto de dados seja centralizado na origem (média zero).

A partir dos dados centralizados X é construída a **matriz de covariância** (frequentemente definida como S ou C_X).

A matriz de covariância mede o grau de relacionamento linear entre as diferentes variáveis do conjunto de dados. Ela é calculada como $S = 1/(N-1)XX^T$

Exemplo - Horas e Notas

Considere a seguinte tabela com n=2 amostras e d=2 características (Horas, Nota):

X =

2	4
4	8

Passo 1: Centralização

Média das horas → (2 + 4) / 2 = 3

Média das notas → (4 + 8) / 2 = 6

Subtrair a média de cada elemento para obter a matriz centralizada

B =

-1	-2
1	2

Exemplo - Horas e Notas

Passo 2: Cálculo da matriz de covariância

$C = 1 / (n-1)B^TB$

$B^TB =$

-1	1
-2	2

.

-1	-2
1	2

=

2	4
4	8

$C = 1/1$

2	4
4	8

=

2	4
4	8

Exemplo - Horas e Notas

2	4
4	8

Variâncias
2 é a variância de horas
8 é a variância de notas

Covariância entre horas e notas

Como o valor é positivo a tendência é que, quando as horas aumentam, a nota também tende a aumentar

Análise dos Componentes Principais (PCA)

Com base na matriz de correlação é necessário calcular os autovetores e autovalores.

Autovetores (Componentes Principais): Os autovetores u_i da matriz de covariância S definem as direções do novo espaço vetorial (o subespaço principal). Eles são garantidamente ortogonais entre si porque a matriz de covariância é simétrica.

Autovalores (Variância Capturada): Cada autovalor λ_i correspondente a um autovetor u_i e representa exatamente a variância dos dados ao longo daquela direção.

O PCA ordena esses autovetores com base em seus autovalores em ordem decrescente ($\lambda_1 \geq \lambda_2 \geq \ldots$). O autovetor associado ao maior autovalor é o "primeiro componente principal" e aponta na direção de maior espalhamento dos dados.

Exemplo - Horas e Notas

Calcular autovalores e autovetores

Ao resolver a equação $Su = \lambda u$ são obtidos os autovetores (u) e os autovalores (λ)

Para a matriz do exemplo:

$\lambda_1 = 0$; $\lambda_2 = 10$

$u_1 = [-0.89442719, 0.4472136]$; $u_2 = [-0.4472136, -0.89442719]$

Como λ_1 é 0 o seu autovetor pode ser ignorado (0 variância)

Exemplo - Horas e Notas

Projetando os dados

u_2 é o autovetor escolhido pois seu autovalor associado possui o maior valor

$$\begin{bmatrix} -1 & -2 \\ 1 & 2 \end{bmatrix} \cdot \begin{bmatrix} -0.4472136 \\ -0.89442719 \end{bmatrix} = \begin{bmatrix} 2.2361 \\ -2.2361 \end{bmatrix}$$

Exemplo - PCA no MNIST

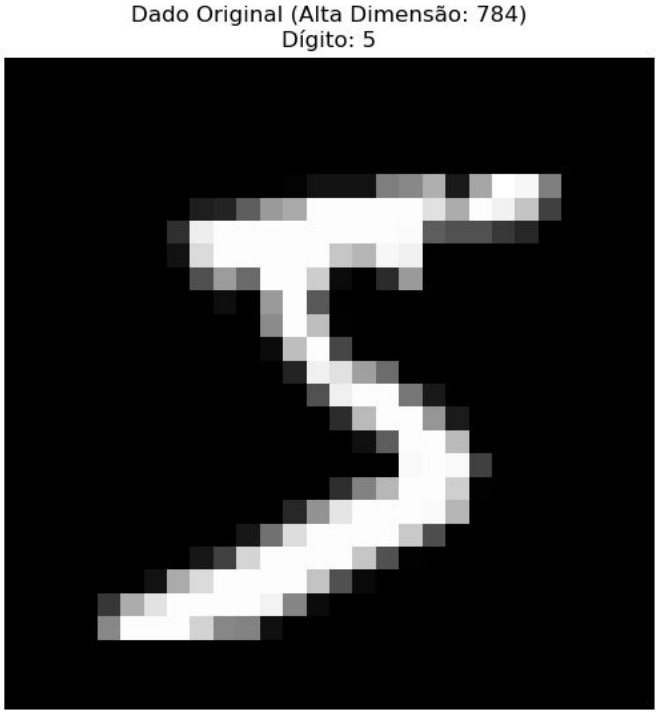

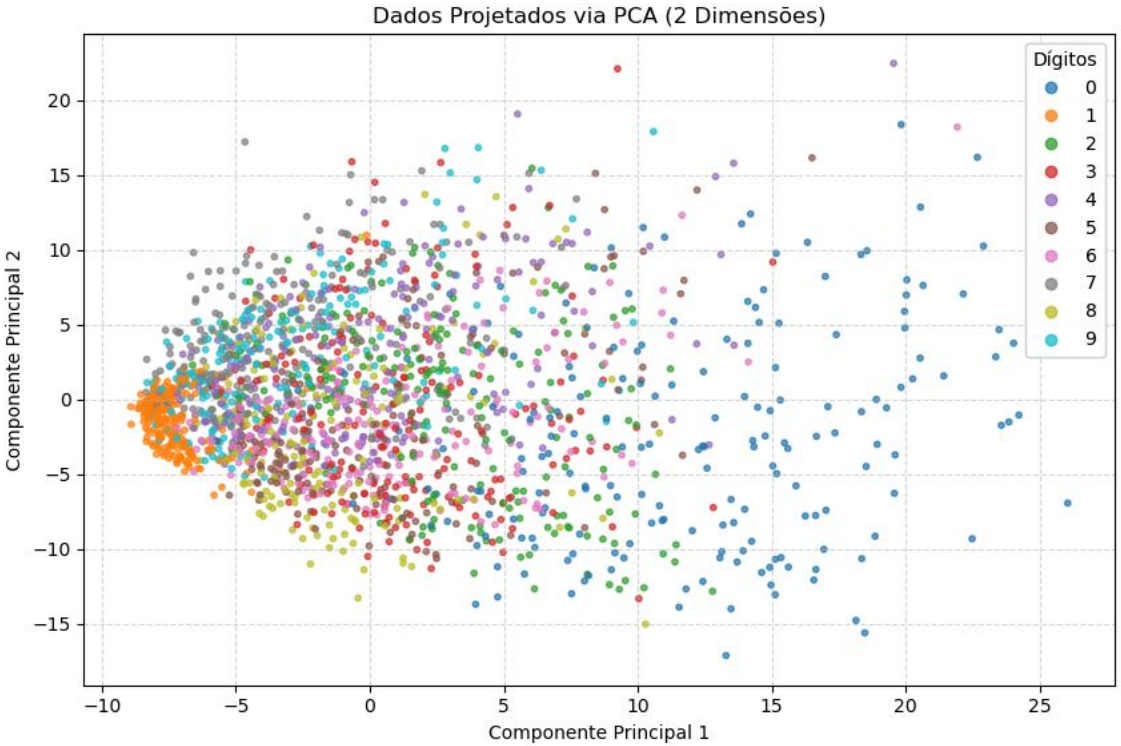

Exemplo - PCA no MNIST

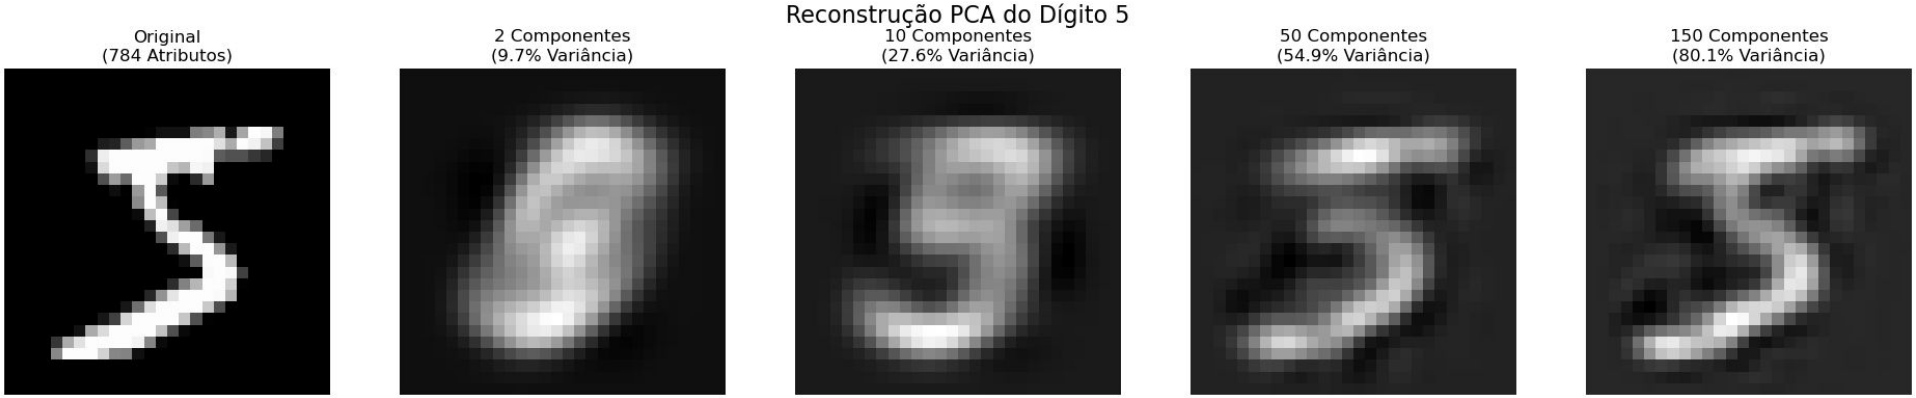

Problemas em calcular XX^T

Pode elevar ao quadrado o número de condição da matriz, causando perda severa de precisão numérica e instabilidade

A solução matemática e algorítmica para isso é a **Decomposição em Valores Singulares (SVD)**

Decomposição em Valores Singulares (SVD)

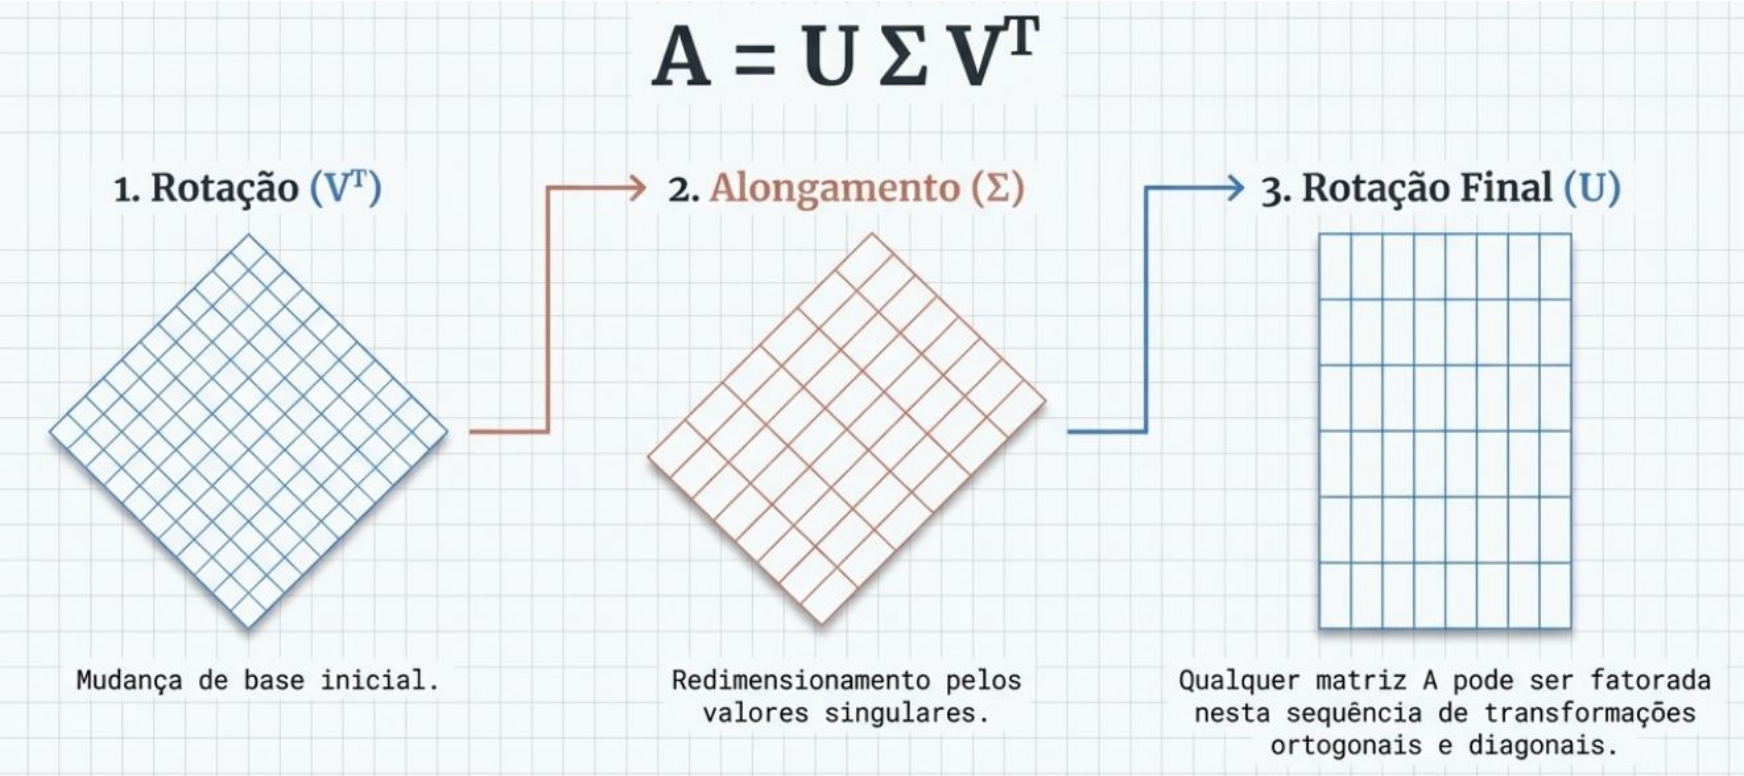

Decomposição em Valores Singulares (SVD)

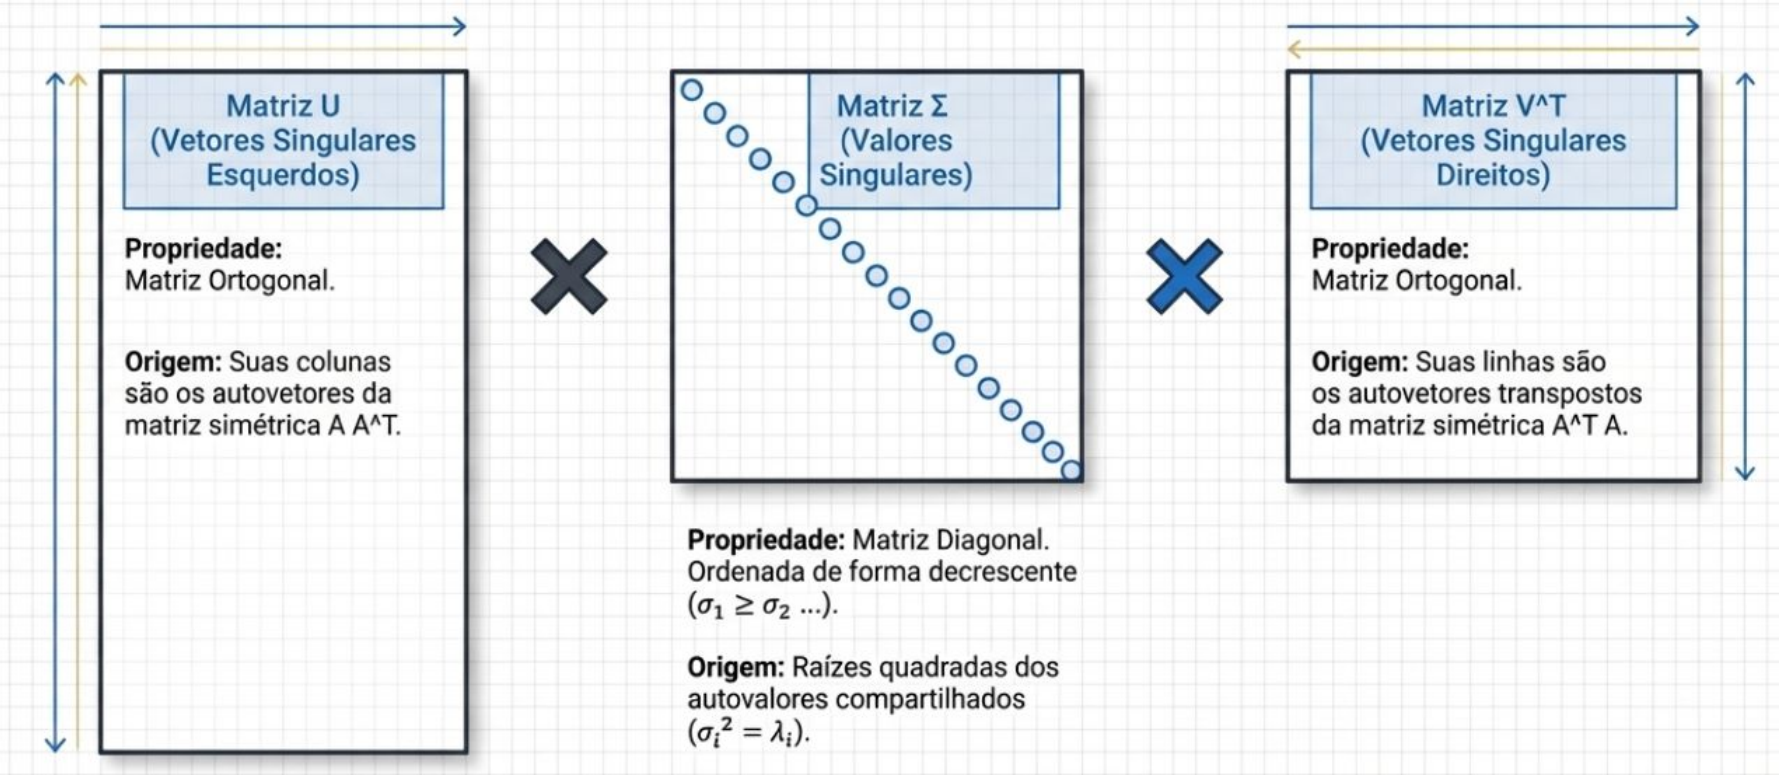

SVD como autoencoder linear

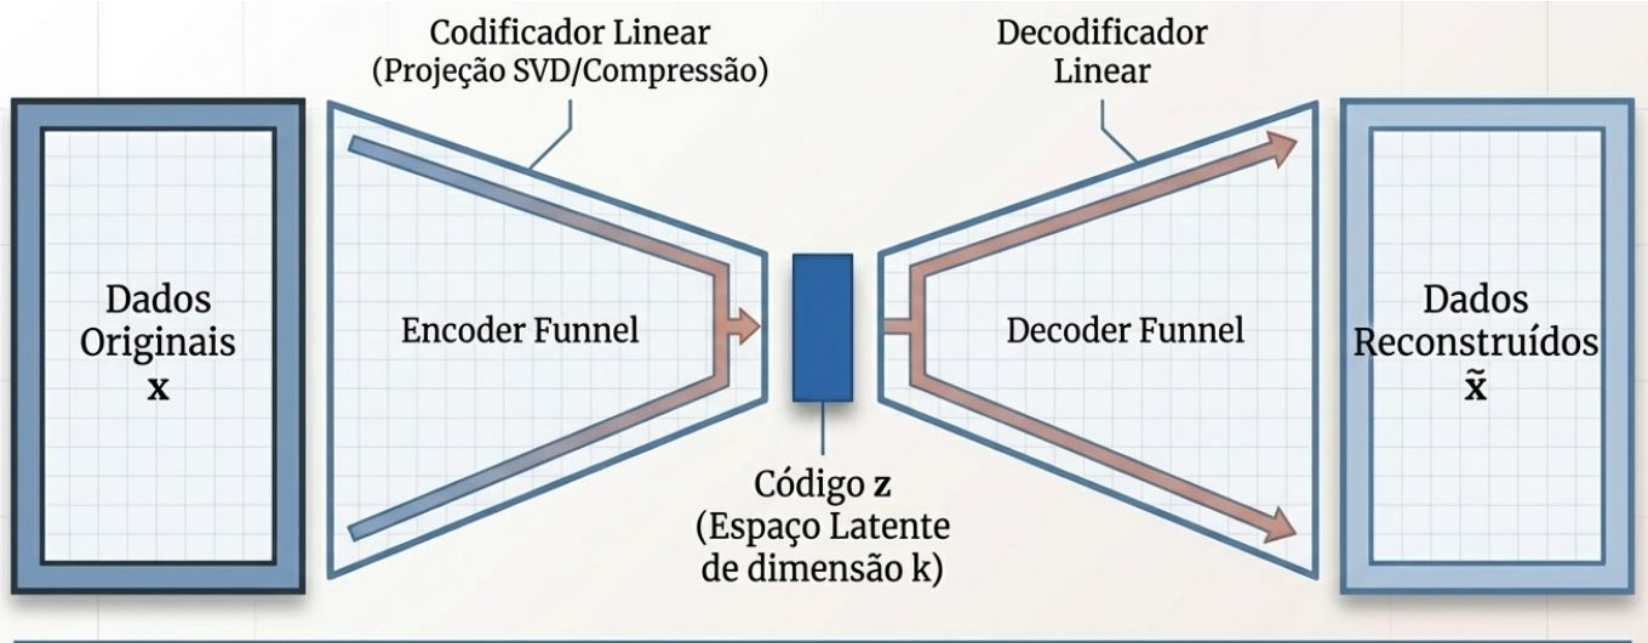

O PCA/SVD atua como o sistema linear ótimo, garantindo o menor erro quadrático médio de reconstrução possível ao passar por um gargalo de informação.

PCA e Reconhecimento Facial

Imagens de rostos humanos são dados de alta dimensão (cada pixel é um atributo). No entanto, rostos não são aleatórios; eles possuem estruturas comuns (distância entre olhos, formato do nariz, etc.). O PCA nos permite encontrar essas "direções de variação" principais, que chamamos de Eigenfaces.

Você deve implementar um script em Python que utilize o banco de dados Labeled Faces in the Wild (LFW) para extrair as características fundamentais dos rostos humanos.