Métodos Probabilísticos I

Likelihood, Prior, Posterior e Teorema de Bayes.

Dr. João Baptista Cardia Neto

18 de março de 2026

FATEC Marília

Fundamentos Probabilísticos

Teorema de Bayes e o Raciocínio Probabilístico

Qual a probabilidade do seu vizinho ser um alienígena?

Teorema de Bayes e o Raciocínio Probabilístico

Qual a probabilidade do seu vizinho ser um alienígena?

E se você ouve ele falando em línguas estranhas que nunca tinha ouvido antes?

E se você visse algo no formato de um disco flutuando na frente da janela dele?

Teorema de Bayes e o Raciocínio Probabilístico

Um teste de gravidez gera um resultado positivo para pessoas não grávidos em 0.1% das vezes. Ao receber um resultado positivo, você está realmente grávida?

Teorema de Bayes e o Raciocínio Probabilístico

- Considerando 100000 mulheres que fizeram um teste de gravidez após ter tido relação;
- Suponha que 200 das 100.000 estão grávidas (0.2%);
  - Nenhum falso negativo;
- Sendo assim 99800 não estão grávidas;
- Taxa de 0.1% de falsos positivos;
  - Numa população de 99800 teríamos 99.8 positivos;
- No total 299.8 positivos e 99700.2 negativos;
- Assim, temos:

$$\frac{99.8}{299.8} \approx 33.29\% \tag{1}$$

Teorema de Bayes e o Raciocínio Probabilístico

- Cinco sacos de doces estão misturados com os sabores de cereja e lima;
- Os doces são vendidos em sacos bem grandes, impossível de distinguir seu conteúdo;
- Existem cinco tipos:
  - $h_1 \rightarrow$ 100% Cereja;
  - $h_2 \rightarrow$ 75% Cereja + 25% Lima;
  - $h_3 \rightarrow$ 50% Cereja + 50% Lima;
  - $h_4 \rightarrow$ 25% Cereja + 75% Lima;
  - $h_5 \rightarrow$ 100% Lima;
  - Probabilidades $\rightarrow$ h_1: 10%; h_2: 20%; h_3: 40%; h_4: 20%; h_5: 10%;
- Conforme você retira doces do saco, como isso altera a probabilidade de ser uma das hipóteses?

Teorema de Bayes e o Raciocínio Probabilístico

Ao enfiar a mão no saco e tirar uma bala de lima, a *posteriori* de h_1 se dá por:

$$h_1' = \frac{P(lima|h_1) \times P(h_1)}{P(lima)} = \frac{0 \times 0.1}{0.5} \tag{2}$$

E h_2:

$$h_2' = \frac{P(lima|h_2) \times P(h_2)}{P(lima)} = \frac{0.25 \times 0.2}{0.5} \tag{3}$$

Teorema de Bayes e o Raciocínio Probabilístico

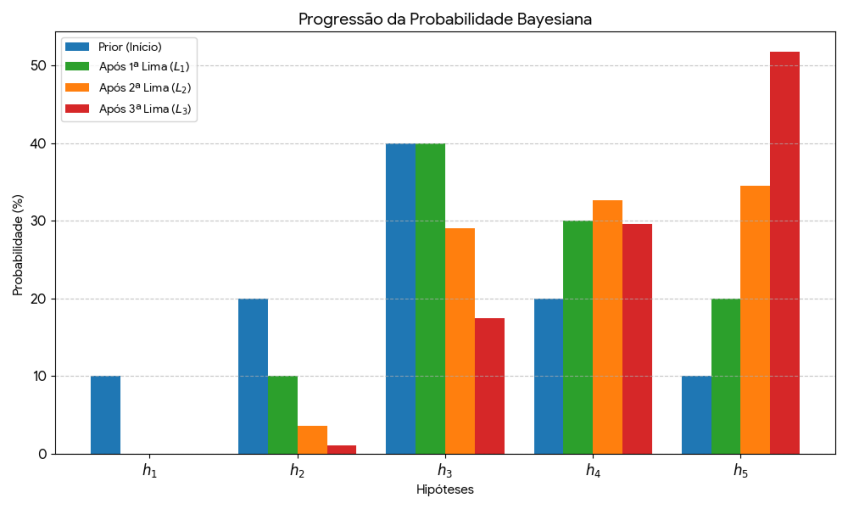

Figura 1: Progressão das probabilidades com a observação de mais amostras

Teorema de Bayes e o Raciocínio Probabilístico

No contexto de aprendizado de máquina, queremos encontrar a probabilidade dos parâmetros θ dado os dados coletados D:

$$P(\theta|D) = \frac{P(D|\theta)P(\theta)}{P(D)} \tag{4}$$

- **Prior** $P(\theta)$: O que sabemos antes dos dados.
- **Likelihood** $P(D|\theta)$: Quão bem os parâmetros explicam os dados.
- **Posterior** $P(\theta|D)$: Nossa crença atualizada.

Teorema de Bayes e o Raciocínio Probabilístico

Em ML podemos usar a notação:

$$p(w|D) = \frac{p(D|w)p(w)}{p(D)} \tag{5}$$

- A relação do teorema pode ser expressada por: *posterior* $\propto$ *likelihood* $\times$ *prior*;
- O denominador da conta atua somente como uma constante de normalização;
  - Garante que a posteriori seja uma densidade de probabilidade válida e integre a um;

A priori (prior)

- Nosso conhecimento sobre um evento antes de observarmos um novo dado;
- Uma escolha adequada da priori pode evitar overfitting.

Verossimilhança (likelihood)

- Expressa o quão provável é o conjunto de dados observados para diferentes configurações de parâmetros do modelo;
- Não é uma distribuição de probabilidades, já que sua integral sobre um parâmetro (no caso w) não é necessariamente 1.

A Posteriori (Posterior)

- A probabilidade depois que observamos novos dados;
- Representa a incerteza revisada sobre os parâmetros após os dados de treinamento terem sido incorporados.

Estimativa de Máxima Verossimilhança (MLE)

O objetivo do MLE é encontrar o $\hat{w}$ que maximiza a função de verossimilhança:

Objetivo de Otimização

$$\hat{w}_{MLE} = \arg\max_{w} \mathcal{L}(w; D)$$

Em implementações práticas (como redes neurais), costumamos minimizar a **Negative Log-Likelihood (NLL)**:

- Transforma produtos em somas.
- Facilita a estabilidade numérica.
- Por ser uma abordagem frequentista, trata os parâmetros como valores fixos, porém desconhecidos.
- Como o log é monotonicamente crescente, maximizar o log é o mesmo que maximizar a função original.
- Em ML maximizar o log é o mesmo que minimizar a função de loss.

Estimativa de Máxima Verossimilhança (MLE)

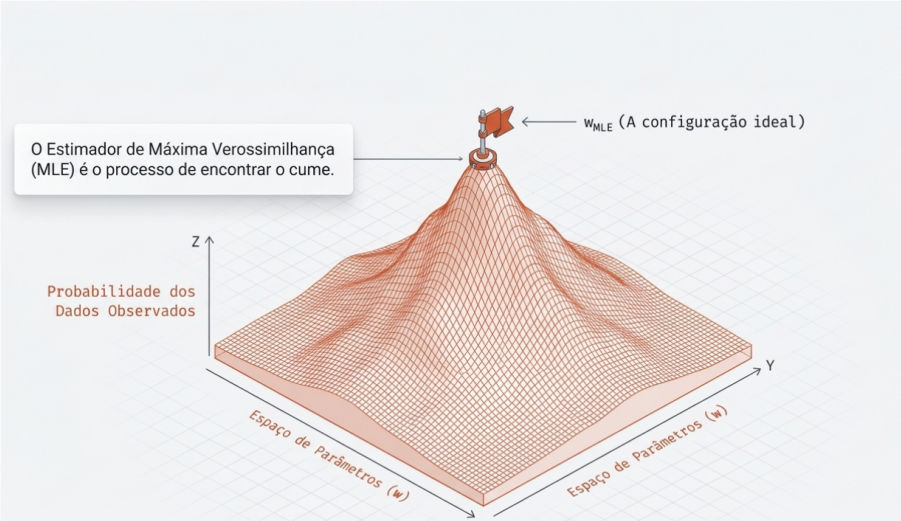

Figura 2: A escalada do MLE

O problema das três moedas

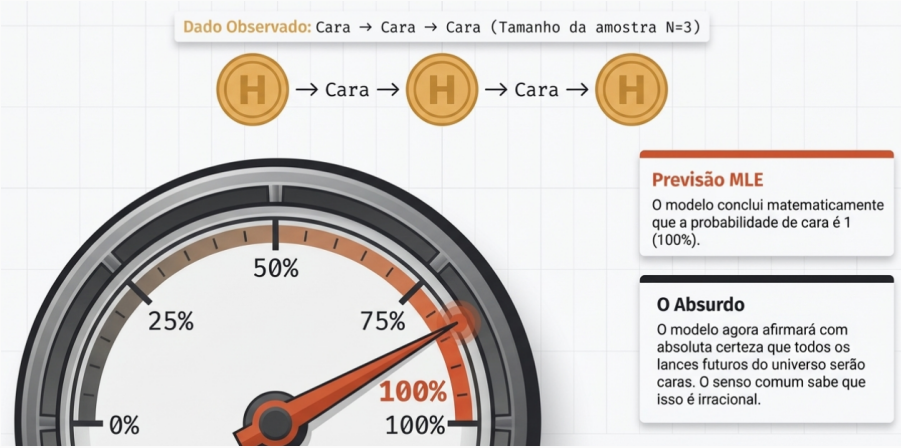

Figura 3: O problema das três moedas

Comparativo de Paradigmas: Bayes vs. MLE

Característica	Bayes	MLE
Natureza de w	Variável aleatória (Distribuição)	Valor fixo e desconhecido
Base da Decisão	Dados empíricos + Conhecimento *a priori*	Exclusivamente os dados observados
Otimização	Mapeia a incerteza (*Posteriori*)	Busca o pico absoluto (Maximiza a função)
Vulnerabilidade	Subjetividade na escolha da *Prior*	Severo *Over-fitting* em dados pequenos

Comparativo de Paradigmas: Bayes vs. MLE

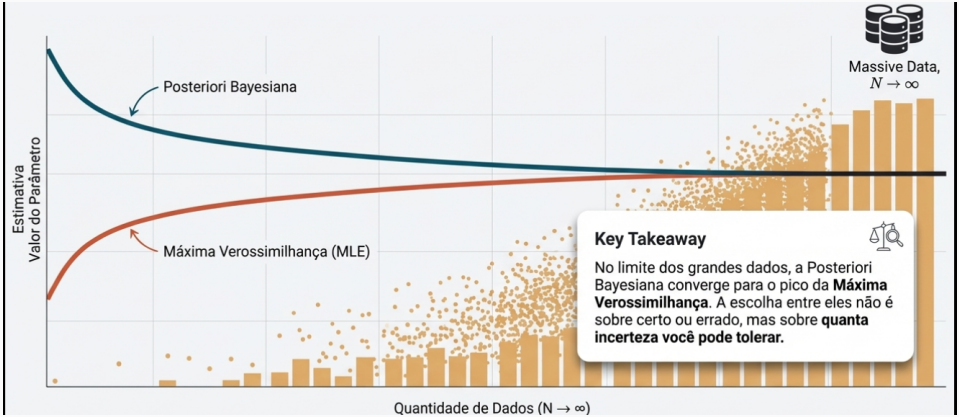

Figura 4: Comparando MLE e Bayes

Naive Bayes

- Aplica a probabilidade condicional, mas com uma suposição ingênua;
- Assume que todas as variáveis são condicionalmente independentes entre elas;
- Só dependem da classe;
- A verossimilhança se torna o produto das probabilidades de cada variável.

$$\hat{w}_{NB} = \textbf{argmax}_{w_j \in W} P(w_j) \prod_i P(a_i | w_j) \tag{6}$$