Regressão Linear

Spoiler: Não é um grande regresso reto

Dr. João Baptista Cardia Neto

29 de abril de 2026

FATEC Marília

Regressão Linear

Prevê o valor contínuo de uma variável a partir de uma ou mais características. Faz uma previsão computando uma soma ponderada das features adicionando um termo constante (chamado de viés, bias ou intercept)

Em um conjunto de dados unidimensional:

$$y_i = k \cdot x_i + d + \epsilon_i \tag{1}$$

Em um conjunto de dados com múltiplas variáveis:

$$\hat{y} = h_\theta(x) = \theta \cdot x \tag{2}$$

ou

$$y = X\beta + \epsilon \tag{3}$$

Regressão Linear

É necessário cumprir algumas premissas:

Linearidade: O comportamento do sistema deve ser uma combinação linear das variáveis preditoras;

Variância Constante: Os erros devem possuir uma variância igual em todas as faixas de valores (Homocedasticidade);

Independência de erros: Os erros não devem estar correlacionados;

Ausência de multicolinearidade: As features não devem ser perfeitamente correlacionadas umas com as outras.

Regressão Linear

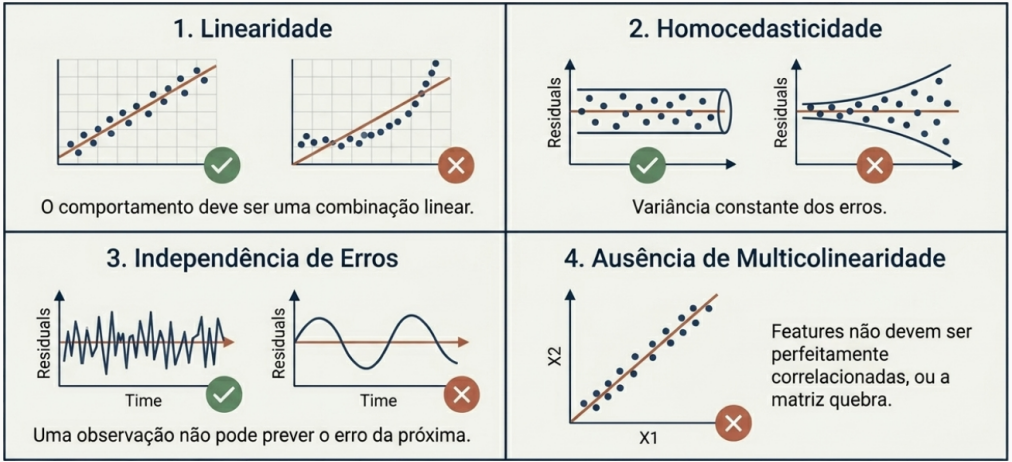

Figura 1: As premissas da regressão linear

Mínimos Quadrados Ordinários

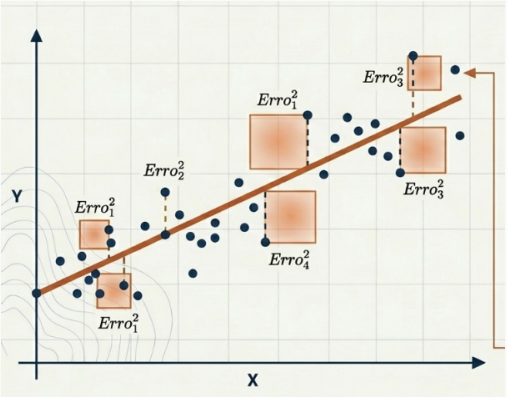

Figura 2: Reta

Como definir o melhor modelo?

- Busca minimizar a soma dos erros ao quadrado;
- Usamos o erro quadrático médio (Minimum Squared Error - MSE) como uma função de loss;
- O objetivo do algoritmo é encontrar o valor do parâmetro θ que minimize o MSE.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \tag{4}$$

Avaliação do modelo

Uma das formas de avaliar modelos de regressão linear é a utilização do R^2. Ele responde a pergunta: "Quanto da variação dos meus dados o meu modelo consegue explicar?"ou, sendo mais formal, indica a proporção da variação da variável dependente que é explicada pela variação das variáveis independentes

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} \tag{5}$$

onde:

SS_{res} é a soma de todos os erros;

SS_{tot} é a soma dos valores reais menos a média dos valores.

Importante: Um R^2 alto não significa que o modelo é bom, apena indica que o modelo se ajusta bem aos dados observados.

Avaliação do modelo

O R^2 sempre aumenta quando você adiciona uma nova variável, independente de sua importância para o modelo. Ideal usar o R^2 ajustado

$$R^2_{adj} = 1 - \left[\frac{(1 - R^2)(n - 1)}{n - p - 1}\right] \tag{6}$$

onde:

n tamanho da minha amostra;

p número de features.

Implementando o regressor

Implementar a regressão linear em dois cenários:

Em um conjunto de dados unidimensional

Em um conjunto de dados multidimensional

Formas de solução

É possível encontrar os parâmetros do modelo de duas formas:

Solução analítica (closed-form solution): Utiliza uma equação fechada que fornece direto os valores do modelo $\hat{\theta} = (X^T X)^{-1} X^T y$;

Otimização via gradiente descendente: Quando há excesso de dados ou features a solução analítica não é possível.

Gradiente descendente

Figura 3: Gradiente descendente

Necessidade da normalização

Deixar todos os dados na mesma escala é de suma importância numa abordagem de gradiente descendente.

- Um atributo com uma escala muito maior que outros pode enviesar o processo de construção do modelo;
- No caso da utilização do MSE a função pode assumir o formato de uma "bacia alongada"e transformar o processo de convergência muito mais lento.

Necessidade de normalização

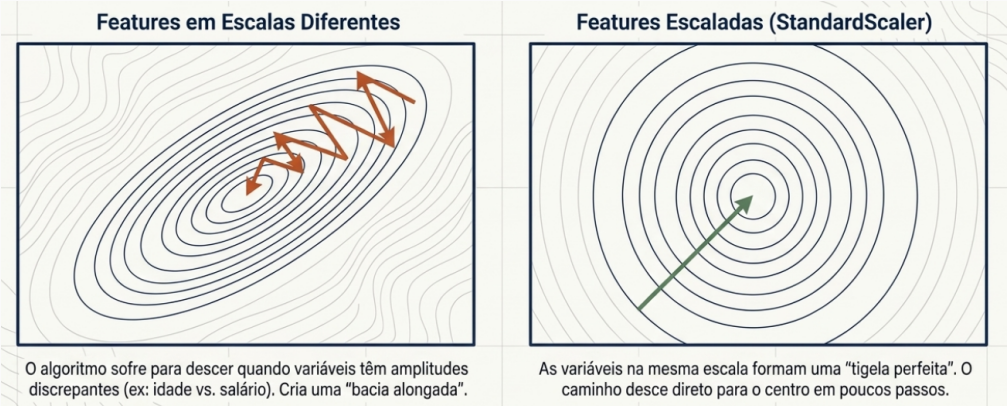

Figura 4: GD com e sem normalização

Estratégias de Otimização: Comparativo

	Solução Analítica	Batch GD	Stochastic GD	Mini-Batch GD
Volume Massivo de Amostras	✗	✗	✓	✓
Milhares de Variáveis	✗	✓	✓	✓
Requer normalização	Não	Sim	Sim	Sim
Suporta Out-of-Core	Não	Não	Sim	Sim

A Solução Analítica é perfeita para bases pequenas. Para Big Data, as variantes SGD e Mini-Batch são o padrão da indústria.