

Árvores de decisão

Como uma árvore me ajuda a decidir?

Dr. João Baptista Cardia Neto

13 de maio de 2026

FATEC Marília

Entropia de Shannon




Figura 1: Aprendizado indutivo

Entropia de Shannon

Quantifica o nível de incerteza ou impureza em uma coleção de dados S .

Equação da Entropia

$$\text{Entropia}(S) = - \sum_{i=1}^c p_i \log_2 p_i$$

Onde p_i é a proporção de exemplos em S da classe i .

Escala:

- Máxima Pureza (1 classe): Entropia = 0.
- Máxima Impureza (Booleano 50/50): Entropia = 1.




Figura 2: Entropia

Mede a **redução da entropia** esperada ao particionar os dados por um atributo A . Representa o número de bits economizados na codificação ao conhecer A .

Cálculo do Ganho

$$Gain(S, A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

- Atributos com maior ganho são melhores classificadores.

- Aprendizado Indutivo (do específico para o geral).
- Representação: Nó raiz $\rightarrow$ Nós internos (testes) $\rightarrow$ Folhas (classes).
- **Vantagens:**
 - Lida com expressões disjuntivas.
 - Robusta a ruídos nos dados.

O Algoritmo ID3 (Quinlan, 1986)

- **Abordagem:** Gulosa (*Greedy*), sem retrocesso (*backtracking*).
- **Construção:** Top-down a partir do nó raiz.
- **Viés Indutivo:**
 - Prioriza árvores curtas.
 - Atributos de alto Ganho de Informação ficam próximos à raiz.
- **Vulnerabilidade:** Tende a favorecer atributos com muitos valores únicos (ex: IDs, Datas).
- **Solução:** *Gain Ratio* (Razão de Ganho), que penaliza divisões muito amplas.

Sucessor do ID3 focado em problemas práticos reais:

1. **Combate ao Overfitting:** **Rule Post-Pruning** (Pós-poda de regras).
 - Converte árvore em regras "SE-ENTÃO".
 - Remove condições se a precisão estimada aumentar.
2. **Atributos Contínuos:** Cria limiares (*thresholds*) dinâmicos.
3. **Valores Ausentes:** Utiliza estimativas fracionárias baseadas em probabilidades.

- Mede a probabilidade de um elemento ser classificado incorretamente.
- **Fórmula:**

$$Gini(m) = \sum_{k=1}^K \hat{p}_{mk}(1 - \hat{p}_{mk}) = 1 - \sum_{k=1}^K \hat{p}_{mk}^2$$

- **Interpretação:** Variância da resposta binária no nó.
- Frequentemente usado no algoritmo CART.

Comparação Técnica: Gini vs. Entropia

Característica	Gini	Entropia
Cálculo	Mais rápido (sem log)	Mais lento (computacionalmente)
Sensibilidade	Alta (busca pureza)	Alta (busca pureza)
Diferenciável	Sim	Sim
Uso Principal	Algoritmo CART	ID3, C4.5

Observação Crucial

Ambos recompensam divisões que geram **nós puros**, mesmo que o erro bruto de classificação seja o mesmo em outros cenários.

- **Fase de Crescimento:** Use **Entropia** ou **Gini**. São mais sensíveis às probabilidades dos nós e guiam melhor a busca inicial.
- **Fase de Poda:** O erro de classificação simples (*misclassification error*) é frequentemente utilizado no *cost-complexity pruning* para simplificar a árvore final.